IDENTIFIKASI MEME *SELF-HARM* MENGGUNAKAN *INTERMEDIATE FUSION* MODEL MULTIMODAL CLIP DAN ELECTRA

TUGAS AKHIR

Diajukan sebagai syarat menyelesaikan jenjang strata Satu (S-1) di Program Studi Teknik Informatika, Fakultas Teknologi Industri, Institut Teknologi Sumatera

Oleh:

Elsa Elisa Yohana Sianturi

122140135

ITERA

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS TEKNOLOGI INDUSTRI

INSTITUT TEKNOLOGI SUMATERA

LAMPUNG SELATAN

2026

LEMBAR PENGESAHAN

Tugas Akhir Sarjana dengan judul ”Identifikasi Meme *Self-Harm* Menggunakan *Intermediate Fusion* Model Multimodal CLIP dan ELECTRA” adalah benar dibuat oleh saya sendiri dan belum pernah dibuat dan diserahkan sebelumnya, baik sebagian ataupun seluruhnya, baik oleh saya ataupun orang lain, baik di Institut Teknologi Sumatera maupun di institusi pendidikan lainnya.

Lampung Selatan, 28-03-2026

Penulis,

Foto 3x4

Elsa Elisa Yohana Sianturi

NIM 122140135

Diperiksa dan disetujui oleh,

Pembimbing	Tanda Tangan
1. Martin Clinton Tosima Manullang, Ph.D. NIP. 19930109 2019 03 1 017	.....

Penguji	Tanda Tangan
1. Andika Setiawan, S.Kom., M.Cs. NIP. 19911127 2022 03 1 007	.....
2. Eko Dwi Nugroho, S.Kom., M.Cs. NIP. 19910209 2024 06 1 001	.....

Disahkan oleh,

Koordinator Program Studi Teknik Informatika

Fakultas Teknologi Industri

Institut Teknologi Sumatera

Andika Setiawan, S.Kom., M.Cs.

NIP 19911127 2022 03 1 007

HALAMAN PERNYATAAN ORISINALITAS

Tugas Akhir dengan judul "Identifikasi Meme *Self-Harm* Menggunakan *Intermediate Fusion* Model Multimodal CLIP dan ELECTRA" adalah karya saya sendiri, dan semua sumber baik yang dikutip maupun dirujuk telah saya nyatakan benar.

Nama	**:**	**Elsa Elisa Yohana Sianturi**
NIM	**:**	**122140135**
Tanda Tangan	**:**	**.....**
Tanggal	**:**	**.....**

HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI
TUGAS AKHIR UNTUK KEPENTINGAN AKADEMIS

Sebagai civitas akademik Institut Teknologi Sumatera, saya yang bertanda tangan di bawah ini:

Nama : Elsa Elisa Yohana Sianturi
NIM : 122140135
Program Studi : Teknik Informatika
Fakultas : Teknologi Industri
Jenis Karya : Tugas Akhir

demi pengembangan ilmu pengetahuan, menyetujui untuk memberikan kepada Institut Teknologi Sumatera **Hak Bebas Royalti Noneksklusif *(Non-exclusive Royalty Free Right)*** atas karya ilmiah saya yang berjudul:

Identifikasi Meme *Self-Harm* Menggunakan *Intermediate Fusion* Model Multimodal CLIP dan ELECTRA

beserta perangkat yang ada (jika diperlukan). Dengan Hak Bebas Royalti Noneksklusif ini Institut Teknologi Sumatera berhak menyimpan, mengalihmedia/formatkan, mengelola dalam bentuk pangkalan data (*database*), merawat, dan memublikasikan tugas akhir saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta.

Demikian pernyataan ini saya buat dengan sebenarnya.

Dibuat di : Lampung Selatan
Pada tanggal : 28-03-2026

Yang menyatakan

Elsa Elisa Yohana Sianturi

KATA PENGANTAR

Puji syukur kehadirat Tuhan Yang Maha Esa atas limpahan rahmat, karunia, serta petunjuk-Nya sehingga penyusunan tugas akhir ini telah terselesaikan dengan baik. Dalam penyusunan tugas akhir ini penulis telah banyak mendapatkan arahan, bantuan, serta dukungan dari berbagai pihak. Oleh karena itu pada kesempatan ini penulis mengucapan terima kasih kepada:

1. Bapak Prof. Dr. I. Nyoman Pugeg Aryantha selaku Rektor Institut Teknologi Sumatera.
2. Bapak Hadi Teguh Yudistira, S.T., Ph.D. selaku Dekan Fakultas Teknologi Industri.
3. Bapak Andika Setiawan, S. Kom., M. Cs. selaku Ketua Program Studi Teknik Informatika.
4. Bapak Martin Clinton Tosima Manullang, Ph.D. selaku Dosen Pembimbing atas ide, waktu, tenaga, perhatian, dan masukan yang telah disumbangsihkan kepada penulis.
5. Teman-teman penulis yang membantu selama masa perkuliahan dan bekerja sama dalam melakukan penelitian tugas akhir yang tidak bisa disebutkan satu persatu.

Akhir kata penulis berharap semoga tugas akhir ini dapat memberikan manfaat bagi kita semua. Penulis menyadari bahwa tugas akhir ini tidak luput dari kekurangan dan kelemahan, dan penulis terbuka untuk menerima saran, kritik, dan masukan.

RINGKASAN

Identifikasi Meme *Self-Harm* Menggunakan *Intermediate Fusion* Model Multimodal CLIP dan ELECTRA

Elsa Elisa Yohana Sianturi

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetuer id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Nam dui ligula, fringilla a, euismod sodales, sollicitudin vel, wisi. Morbi auctor lorem non justo. Nam lacus libero, pretium at, lobortis vitae, ultricies et, tellus. Donec aliquet, tortor sed accumsan bibendum, erat ligula aliquet magna, vitae ornare odio metus a mi. Morbi ac orci et nisl hendrerit mollis. Suspendisse ut massa. Cras nec ante. Pellentesque a nulla. Cum sociis natoque penatibus et magnis dis parturient montes, nascetur ridiculus mus. Aliquam tincidunt urna. Nulla ullamcorper vestibulum turpis. Pellentesque cursus luctus mauris.

ABSTRAK

Identifikasi Meme *Self-Harm* Menggunakan *Intermediate Fusion* Model Multimodal CLIP dan ELECTRA

Elsa Elisa Yohana Sianturi

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetuer id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Kata Kunci: kunci1, kunci2

ABSTRACT

Comparison

Elsa Elisa Yohana Sianturi

Lorem ipsum dolor sit amet, consectetuer adipiscing elit. Ut purus elit, vestibulum ut, placerat ac, adipiscing vitae, felis. Curabitur dictum gravida mauris. Nam arcu libero, nonummy eget, consectetuer id, vulputate a, magna. Donec vehicula augue eu neque. Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Mauris ut leo. Cras viverra metus rhoncus sem. Nulla et lectus vestibulum urna fringilla ultrices. Phasellus eu tellus sit amet tortor gravida placerat. Integer sapien est, iaculis in, pretium quis, viverra ac, nunc. Praesent eget sem vel leo ultrices bibendum. Aenean faucibus. Morbi dolor nulla, malesuada eu, pulvinar at, mollis ac, nulla. Curabitur auctor semper nulla. Donec varius orci eget risus. Duis nibh mi, congue eu, accumsan eleifend, sagittis quis, diam. Duis eget orci sit amet orci dignissim rutrum.

Keywords: keywords1, keywords2

DAFTAR ISI

LEMBAR PENGESAHAN . . . . . **ii**

Halaman Pernyataan Orisinalitas . . . . . **iii**

Halaman Persetujuan Publikasi . . . . . **iv**

KATA PENGANTAR . . . . . **v**

RINGKASAN . . . . . **vi**

ABSTRAK . . . . . **vii**

ABSTRACT . . . . . **viii**

DAFTAR ISI . . . . . **ix**

DAFTAR TABEL . . . . . **xiv**

DAFTAR GAMBAR . . . . . **xv**

DAFTAR RUMUS . . . . . **xvi**

DAFTAR KODE . . . . . **xvi**

BAB I PENDAHULUAN **1**

1.1 Latar Belakang 1

1.2 Rumusan Masalah 7

1.3 Tujuan Penelitian 8

1.4 Batasan Masalah 8

1.5 Manfaat Penelitian 11

1.6 Sistematika Penulisan 11

1.6.1 Bab I Pendahuluan 11

1.6.2 Bab II Tinjauan Pustaka 12

1.6.3 Bab III Metodologi Penelitian 12

1.6.4 Bab IV Hasil dan Pembahasan 12

1.6.5 Bab V Kesimpulan dan Saran 12

BAB II TINJAUAN PUSTAKA **13**
2.1 Tinjauan Pustaka 13
2.2 Dasar Teori 19
2.2.1 *Self-Harm* 19
2.2.2 Meme 20
2.2.3 *Multimodal Deep learning* 20
2.2.4 Klasifikasi *Fusion* dalam *Multimodal Deep learning* 21
2.2.4.1 *Early Fusion* 22
2.2.4.2 *Intermediate Fusion* 22
2.2.4.3 *Late Fusion* 23
2.2.4.4 *Hybrid Fusion* 23
2.2.5 *Computer Vision* 24
2.2.6 *Natural Language Processing* (NLP) 24
2.2.7 *Deep Learning* 25
2.2.8 Transformer 25
2.2.9 *Contrastive Language-Image Pre-training* (CLIP) 28
2.2.10 *Efficiently Learning an Encoder that Classifies Token Replacements Accurately* (ELECTRA) 29
2.2.11 Prapemrosesan Data 31
2.2.11.1 *Resize* Gambar 32
2.2.11.2 Normalisasi Gambar 32
2.2.11.3 Augmentasi Data 33
2.2.11.3.1 *Flip* 33
2.2.11.3.2 *Rotation* 33
2.2.11.3.3 *Color Jitter* 33
2.2.12 Evaluasi 34
BAB III METODE PENELITIAN **36**
3.1 Alur Penelitian 36
3.2 Penjabaran Langkah Penelitian 37
3.2.1 Identifikasi Masalah 37
3.2.2 Studi Literatur 37

3.2.3 Pengumpulan Data 38
3.2.3.1 Pengumpulan Data dari Media Sosial 38
3.2.3.2 Rekayasa Dataset Meme *Self-Harm* 39
3.2.3.3 Dataset Meme Umum sebagai Kandidat *Non-Self-Harm* . . 40
3.2.3.4 Ringkasan Komposisi Dataset Awal 41
3.2.4 *Pre-processing* Awal 42
3.2.5 Anotasi Data 42
3.2.5.1 *Framework Prompting* (*RapGuard*) 43
3.2.5.2 *Annotation Guideline* Berbasis Literatur 44
3.2.5.3 *Ensemble Pseudo-Labeling* 45
3.2.5.4 Penentuan Label 45
3.2.6 *Pre-processing Data* 46
3.2.6.1 *Flip* 46
3.2.6.2 *Rotation* 46
3.2.6.3 *Color Jitter* 47
3.2.6.4 *Lowercasing* 48
3.2.7 Pengembangan Model Arsitektur Multimodal 48
3.2.7.1 Pembagian Data 49
3.2.7.2 Pelatihan model 50
3.2.7.3 *Fusion* model 50
3.2.8 Evaluasi Model 51
3.2.9 Analisis Hasil dan Pembahasan 52
3.3 Alat dan Bahan Tugas Akhir 52
3.3.1 *Software dan Library* 52
3.3.2 Dataset 53
3.4 Ilustrasi Perhitungan Metode 53
3.4.1 Ilustrasi Perhitungan *contrastive loss* (InfoNCE) 53
3.4.2 Ilustrasi Perhitungan *Token Detection Loss* pada ELECTRA 55
3.4.3 Ilustrasi Perhitungan Metrik Evaluasi 56

BAB IV HASIL DAN PEMBAHASAN 58
4.1 Pengumpulan Data 58

4.1.1 Dataset Primer 58
4.1.1.1 Dataset Rekayasa Multimodal 58
4.1.1.2 Dataset Media Sosial 59
4.1.2 Dataset Sekunder 59
4.1.3 Komposisi Dataset 60
4.2 Hasil Anotasi Data 61
4.2.1 Tingkat Kesepakatan Antar Model 61
4.2.2 Distribusi Label Akhir 61
4.3 Hasil *Pre-processing* Data 61
4.3.1 *Pre-processing* Modalitas Gambar 61
4.3.2 *Pre-processing* Modalitas Teks 62
4.3.3 Pembagian Dataset 63
4.4 Hasil Pengembangan Model Multimodal 63
4.4.1 Konfigurasi Model 63
4.4.2 Konfigurasi *Hyperparameter* 63
4.5 Hasil Eksperimen 64
4.5.1 Eksperimen Modalitas Gambar 64
4.5.1.1 Hasil Pelatihan Modalitas Gambar 64
4.5.1.2 Analisis Hyperparameter 64
4.5.1.3 Analisis Proses Pelatihan 65
4.5.2 Eksperimen Modalitas Teks 65
4.5.2.1 Hasil Terbaik Model Teks 65
4.5.2.2 Analisis Hyperparameter 66
4.5.2.3 Analisis Proses Pelatihan 66
4.5.3 Eksperimen Multimodal 66
4.5.3.1 Variasi Dimensi Fitur Teks dan Gambar 66
4.5.3.2 Eksperimen Strategi Penanganan Class Imbalance 67
4.5.3.3 Eksperimen Metode Fusion 67
4.6 Analisis Kesalahan (*Error Analysis*) 68
4.6.1 Kasus *False Positive* 68
4.6.2 Kasus *False Negative* 68

4.7 Pembahasan 69
4.7.1 Keterkaitan dengan Rumusan Masalah 69
4.7.2 Perbandingan dengan Penelitian Terdahulu 69
4.7.3 Implikasi dan Limitasi Penelitian 69

BAB V KESIMPULAN DAN SARAN 70
5.1 Kesimpulan 70
5.2 Saran 70

DAFTAR PUSTAKA 71

LAMPIRAN 76

DAFTAR TABEL

Tabel 2.1 Literasi Penelitian Terdahulu 16
Tabel 2.2 *Confusion Matrix* 34
Tabel 3.1 Komposisi Dataset Awal Penelitian 42
Tabel 4.1 Sumber Data Rekayasa Dataset 59
Tabel 4.2 Komposisi Dataset Awal 60
Tabel 4.3 Distribusi Label Akhir Dataset 61
Tabel 4.4 Pembagian Dataset 63
Tabel 4.5 Konfigurasi *Hyperparameter* Pelatihan 63
Tabel 4.6 Hasil Terbaik Model Modalitas Gambar 64
Tabel 4.7 Pengaruh Learning Rate pada Modalitas Gambar 65
Tabel 4.8 Hasil Terbaik Model Modalitas Gambar 65
Tabel 4.9 Pengaruh Learning Rate pada Modalitas Teks 66
Tabel 4.10 Hasil Eksperimen Variasi Dimensi Fitur 67
Tabel 4.11 Skenario Strategi Loss 67
Tabel 4.12 Hasil Eksperimen Strategi Loss 67
Tabel 4.13 Skenario Metode Fusion 67
Tabel 4.14 Hasil Eksperimen Metode Fusion 68

DAFTAR GAMBAR

Gambar 1.1 Contoh Meme Non Self-Harm 2
Gambar 1.2 Contoh Meme *Self-Harm* 3
Gambar 1.3 Contoh Meme dengan Makna Tersirat [13] 5
Gambar 2.1 Contoh Early Fusion [29] 22
Gambar 2.2 Contoh Intermediate Fusion [29] 22
Gambar 2.3 Contoh Late Fusion [29] 23
Gambar 2.4 Contoh *Hybrid Fusion* [29] 23
Gambar 2.5 Arsitektur Transformer dengan Encoder [37] 27
Gambar 2.6 Arsitektur CLIP [38] 29
Gambar 2.7 Arsitektur ELECTRA [18] 30
Gambar 3.1 Alur Penelitian 36
Gambar 3.2 Perbandingan gambar asli dan hasil augmentasi *flip horizontal* 46
Gambar 3.3 Perbandingan gambar asli dan hasil augmentasi *rotasi acak* . . 47
Gambar 3.4 Perbandingan gambar asli dan hasil augmentasi *color jitter* . . . 47
Gambar 3.5 Alur Pengembangan Model 49
Gambar 3.6 Rancangan Fusion Model Varian 1 51
Gambar 3.7 Rancangan Fusion Model Varian 2 52

DAFTAR RUMUS

Rumus 2.1 *Scaled Dot-Product Attention* 26
Rumus 2.2 Contrastive Loss (InfoNCE) pada CLIP 28
Rumus 2.3 *Replaced Token Detection* (RTD) *Loss* pada ELECTRA 30
Rumus 2.4 Perhitungan Faktor Skala 32
Rumus 2.5 Normalisasi Input Gambar 32
Rumus 2.6 Normalisasi Vektor 32
Rumus 2.7 Perhitungan *Accuracy* 34
Rumus 2.8 Perhitungan *Precision* 35
Rumus 2.9 Perhitungan *Recall* 35
Rumus 2.10 Perhitungan *F1-Score* 35

DAFTAR KODE

BAB I
PENDAHULUAN

1.1 Latar Belakang

Transformasi dunia digital dalam satu dekade terakhir telah membawa dampak besar pada berbagai aspek kehidupan manusia, mulai dari pendidikan, kesehatan, industri kreatif, hingga kesejahteraan sosial. Perubahan ini ditandai oleh munculnya ruang interaksi baru di platform daring, yang memungkinkan masyarakat berbagi informasi, emosi, dan pengalaman hidup dalam berbagai bentuk konten. Perkembangan pesat teknologi informasi dan komunikasi telah mengubah cara manusia berinteraksi, berkomunikasi, dan memproduksi informasi dalam skala global yang menciptakan struktur sosial dan budaya baru serta cara baru dalam berbagi pengetahuan dan pengalaman kolektif. Dalam ranah komunikasi sosial dan interaksi interpersonal, media digital memungkinkan terbentuknya jaringan sosial luas tanpa batas geografis, serta mempercepat penyebaran informasi dan gagasan pada khalayak global [1].

Seiring dengan perkembangan tersebut, media sosial kini menjadi infrastruktur komunikasi utama dunia. Menurut laporan DataReportal, sebuah platform global yang menyajikan analisis digital berbasis data dari mitra riset internasional seperti Kepios, We Are Social, dan Meltwater mencatat bahwa terdapat sekitar 5,04 miliar pengguna media sosial aktif pada awal 2024, atau 62,3% populasi dunia, dengan pertumbuhan tahunan sebesar +5,6%, setara dengan 266 juta pengguna baru sepanjang 2023. Rata-rata waktu penggunaan mencapai 2 jam 23 menit per hari , menunjukkan bahwa platform digital kini menjadi ruang publik yang sangat aktif sebagai tempat berbagai bentuk ekspresi diri, termasuk teks, gambar, dan format *multimodal* seperti meme [2][3]. Meme dalam konteks budaya digital adalah unit konten digital yang memiliki karakteristik bersama, dibuat dengan kesadaran terhadap konten lain, serta disebarluaskan, ditiru, dan dimodifikasi oleh banyak pengguna melalui internet [4].

Sebagai pembanding, tidak semua meme mengandung konten berbahaya. Meme non *self-harm* umumnya hanya menyampaikan humor, kritik sosial, atau ekspresi emosional umum tanpa adanya indikasi sinyal menyakiti diri. Dalam konteks komunikasi digital, meme sering digunakan sebagai media ekspresi yang bersifat ringan dan menghibur, serta tidak selalu berkaitan dengan isu sensitif atau berisiko. Namun, karakteristik meme yang bersifat multimodal, yaitu menggabungkan elemen visual dan tekstual, membuat maknanya tidak selalu dapat ditafsirkan secara langsung dari salah satu modalitas saja [5]. Perbedaan antara meme *non self-harm* dan meme yang mengandung indikasi *self-harm* terletak pada hubungan semantik antara teks dan gambar yang membentuk makna secara implisit.

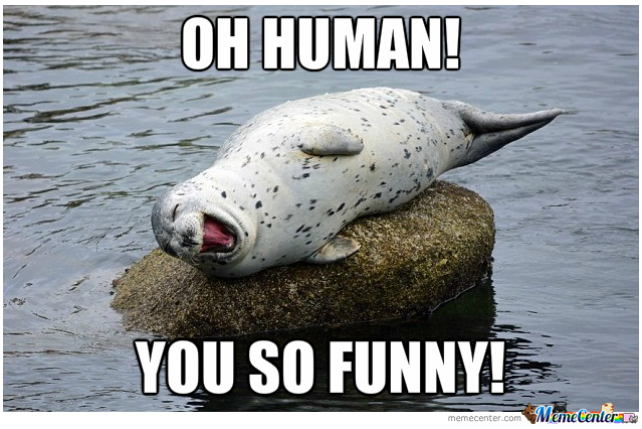

Gambar 1.1 Contoh Meme Non Self-Harm

Gambar 1.1 di atas menunjukkan contoh meme non *self-harm* yang diambil dari dataset penelitian ini dan telah melalui proses anotasi berdasarkan pedoman yang digunakan. Meme ini tidak mengandung indikasi *self-harm* baik dari sisi visual maupun tekstual, sehingga dikategorikan sebagai non *self-harm*.

Berbeda dengan meme yang bersifat umum, terdapat pula meme yang mengandung indikasi *self-harm* yang perlu mendapatkan perhatian khusus. *Self-harm* atau perilaku menyakiti diri sendiri didefinisikan sebagai tindakan yang dilakukan secara sengaja untuk melukai tubuh sendiri, baik dengan maupun tanpa niat bunuh diri, seperti melukai, membakar, atau bentuk cedera diri lainnya. Perilaku ini umumnya berkaitan dengan kesulitan dalam mengelola emosi, tekanan psikologis, atau pengalaman traumatis, dan menjadi salah satu indikator penting dalam kajian kesehatan mental [6][7]. Dalam konteks digital, *self-harm* tidak

hanya merujuk pada tindakan fisik, tetapi juga mencakup representasi, ekspresi, atau penyebaran konten yang berkaitan dengan perilaku menyakiti diri, baik secara eksplisit maupun implisit. Konten ini dapat berfungsi sebagai sarana ekspresi emosional, namun juga berpotensi memperkuat normalisasi atau bahkan mendorong perilaku serupa pada individu lain yang terpapar [8]. Hal ini menunjukkan bahwa konten *self-harm* di media sosial bukan hanya fenomena individu, tetapi juga menjadi permasalahan yang memiliki dampak luas secara sosial. Dalam penelitian ini, *self-harm* tidak diartikan sebagai diagnosis klinis individu, melainkan sebagai indikasi atau representasi *self-harm* dalam konten meme berdasarkan sinyal multimodal (teks dan visual).

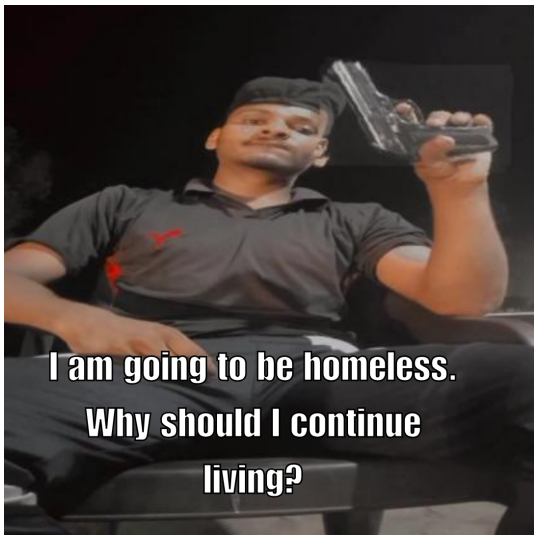

Gambar 1.2 Contoh Meme *Self-Harm*

Gambar 1.2 di atas menunjukkan contoh meme *self-harm* yang diambil dari dataset penelitian ini dan telah melalui proses anotasi berdasarkan pedoman yang digunakan. Meme ini mengandung indikasi *self-harm* yang diperkuat oleh kombinasi antara elemen visual dan tekstual, sehingga maknanya tidak dapat dipahami hanya dari salah satu modalitas saja.

Platform seperti Instagram, Twitter, dan TikTok sering menjadi ruang bagi remaja dan dewasa muda untuk mengekspresikan emosi dan membagikan pengalaman personal, termasuk konten terkait *self-harm*. *Nonsuicidal self-injury* (NSSI) merujuk pada perilaku menyakiti diri tanpa adanya niat untuk mati [6]. Studi *intensive monitoring* pada remaja (pemantauan harian dan mingguan selama

beberapa minggu) menunjukkan bahwa pada minggu-minggu ketika remaja terpapar konten *self-harm* di media sosial, mereka lebih mungkin mengalami dorongan NSSI dan terlibat dalam perilaku NSSI pada periode yang sama, bahkan setelah mengontrol durasi penggunaan media sosial dan gejala depresi [9]. Temuan ini menekankan bahwa paparan jenis konten yang muncul di media sosial dapat menjadi faktor risiko proksimal yang penting, tidak hanya durasi penggunaan (screen time) semata. Paparan tersebut juga dapat terjadi secara tidak disengaja karena sebagian konten sensitif dapat muncul melalui mekanisme rekomendasi pada feed. Sebuah survei berskala besar yang dilakukan oleh Samaritans bersama Universitas Swansea menunjukkan bahwa sebanyak 83% pengguna media sosial pernah direkomendasikan konten bernuansa *self-harm* oleh algoritma *feed*. Rekomendasi tersebut muncul, misalnya, pada halaman *Explore* di Instagram atau *For You* di TikTok, meskipun pengguna tidak secara aktif mencarinya [10]. Temuan ini menunjukkan bahwa isu kesehatan mental pada kelompok usia tersebut merupakan tantangan kesehatan masyarakat yang serius [11].

Dalam konteks ini, meme sebagai bentuk konten digital memiliki karakteristik yang unik. Pesan sering disampaikan secara implisit melalui perpaduan visual dan teks, sehingga pemahamannya bergantung pada hubungan antar-keduanya dan tidak dapat ditafsirkan hanya dari salah satu modalitas saja. Fenomena ini menunjukkan bahwa pemaknaan terhadap meme memerlukan pemrosesan lebih dari satu jenis informasi secara bersamaan. Dalam bidang kecerdasan buatan, pendekatan yang memanfaatkan lebih dari satu jenis sumber data disebut *multimodal learning*, yaitu metode pembelajaran mesin yang memanfaatkan lebih dari satu jenis data seperti teks, gambar, audio, atau video untuk memperoleh pemahaman yang lebih utuh terhadap suatu informasi. Secara konseptual, modalitas merujuk pada cara suatu informasi dialami atau direpresentasikan (misalnya bahasa/teks dan visual/gambar). Suatu permasalahan disebut *multimodal* ketika melibatkan lebih dari satu modalitas yang perlu diinterpretasikan dan dihubungkan secara bersama, bukan secara terpisah, agar makna yang muncul dapat dipahami secara utuh [12]. Pendekatan ini menjadi penting dalam analisis konten digital seperti meme, di mana makna sering muncul dari kombinasi antara elemen visual dan teks yang saling melengkapi.

Penelitian yang dilakukan pada tahun 2021 oleh Kiela et al., meme seringkali menyembunyikan makna yang lebih mendalam yang hanya bisa dipahami dengan menggabungkan konteks visual dan tekstual. Gambar 1.3 di bawah ini menggambarkan kalimat *"Look how many people love you"* bisa terlihat tidak berbahaya jika dipisahkan, namun jika dipasangkan dengan gambar padang gurun, maknanya bisa berubah menjadi sesuatu yang lebih negatif. Fenomena ini menggambarkan bagaimana model berbasis *unimodal* sering kali kesulitan untuk mendeteksi nuansa yang hanya bisa dipahami melalui pemahaman *multimodal*, yakni gabungan antara teks dan gambar [13]. Hal ini menunjukkan bahwa pemahaman multimodal menjadi kunci dalam menginterpretasikan makna meme yang bersifat implisit.

Gambar 1.3 Contoh Meme dengan Makna Tersirat [13]

Shah et al. pada tahun 2024 menjelaskan bahwa gambar yang memuat teks membutuhkan pemahaman *multimodal* mendalam untuk menafsirkan makna tersirat tersebut [14]. Tantangan ini semakin diperjelas oleh Sharma et al. pada tahun 2022 yang menunjukkan bahwa sebagian besar penelitian masih berfokus pada deteksi *hate speech*, sementara jenis konten berbahaya lainnya seperti *self-harm* dan ekstremisme masih sangat kurang dieksplorasi akibat keterbatasan *dataset* publik [5]. Untuk mengatasi keterbatasan *dataset* berlabel, pendekatan *pseudo-labeling* digunakan. *Pseudo-labeling* adalah teknik dimana model yang sudah dilatih digunakan untuk memberi label pada data yang tidak berlabel sehingga memperluas *dataset* tanpa memerlukan anotasi manual [15]. Teknik ini memungkinkan pelatihan model dengan data tambahan meskipun dengan label yang lemah, yang mengatasi keterbatasan *annotator*. Namun, kondisi ini juga menggarisbawahi adanya kesenjangan riset yang signifikan terkait deteksi meme dengan nuansa

self-harm. Meskipun berbagai penelitian telah dilakukan dalam bidang deteksi konten berbahaya berbasis *multimodal*, sebagian besar studi masih berfokus pada kategori seperti *hate speech*, *offensive content*, dan *propaganda*. Sementara itu, konten dengan nuansa *self-harm*, khususnya dalam bentuk meme, masih sangat terbatas untuk diteliti. Padahal, meme *self-harm* memiliki karakteristik unik, yaitu menyampaikan makna secara implisit melalui kombinasi teks dan visual yang sering kali dikemas dalam bentuk humor gelap atau ironi, sehingga berpotensi menormalisasi perilaku menyakiti diri tanpa terdeteksi secara langsung. Selain itu, keterbatasan *dataset* berlabel pada domain ini semakin memperbesar kesenjangan penelitian [16]. Oleh karena itu, diperlukan pendekatan yang mampu memahami hubungan multimodal secara mendalam untuk mendeteksi meme *self-harm* secara lebih akurat.

Sejalan dengan perkembangan *multimodal learning*, model pra-latih *multimodal* seperti CLIP (*Contrastive Language-Image Pre-training*) dirancang untuk mempelajari keterkaitan semantik antara data visual dan tekstual melalui pelatihan pada pasangan gambar dan teks dalam skala besar. Model ini terdiri dari dua *encoder* terpisah, yaitu *image encoder* dan *text encoder*, yang memproyeksikan kedua modalitas ke dalam ruang representasi bersama. CLIP dilatih menggunakan pendekatan *contrastive learning*, yang bertujuan untuk memaksimalkan kesamaan antara pasangan gambar dan teks yang relevan serta meminimalkan kesamaan dengan pasangan yang tidak sesuai. Secara khusus, *image encoder* pada CLIP menunjukkan kemampuan representasi visual yang sangat kuat, karena dilatih menggunakan 400 juta pasangan gambar dan teks dari berbagai domain. Skala data yang besar dan beragam ini memungkinkan model untuk menangkap fitur visual yang kaya dan *generalizable*, sehingga mampu memahami berbagai konteks visual secara lebih akurat [17]. Di sisi teks, model pra-latih seperti ELECTRA (*Efficiently Learning an Encoder that Classifies Token Replacements Accurately*) menawarkan pendekatan yang berbeda dibandingkan metode *masked language modeling* (MLM) yang umum digunakan. ELECTRA menggunakan skema pelatihan diskriminatif yang dikenal sebagai *replaced token detection*, di mana model dilatih untuk membedakan apakah suatu *token* dalam kalimat merupakan *token* asli atau hasil penggantian oleh

generator. Pendekatan ini memungkinkan proses pembelajaran terjadi pada seluruh posisi *token* dalam satu waktu, tidak terbatas hanya pada *token* yang di-*masking* seperti pada MLM [18].

Dalam penelitian ini, pemanfaatan CLIP dan ELECTRA diintegrasikan melalui skema *intermediate fusion* (*feature-level fusion*), yaitu strategi penggabungan representasi ketika masing-masing modalitas telah dipetakan menjadi fitur tingkat tinggi sebelum dilakukan proses klasifikasi. Pada pendekatan ini, representasi visual yang dihasilkan oleh *image encoder* CLIP dan representasi tekstual dari ELECTRA digabungkan dalam satu ruang fitur, sehingga model dapat mempelajari hubungan semantik lintas modalitas secara lebih mendalam. Pendekatan *intermediate fusion* dipandang relevan untuk analisis meme karena memungkinkan model menangkap interaksi kompleks antara elemen visual dan teks pada level representasi, bukan hanya mengandalkan salah satu modalitas (*unimodal*) atau menggabungkan hasil keputusan akhir (*late fusion*). Dengan demikian, model diharapkan mampu memahami makna implisit yang sering muncul dalam meme, termasuk konten dengan nuansa sensitif seperti *self-harm* [19].

Dengan mempertimbangkan kompleksitas makna pada meme serta potensi dampaknya terhadap kesehatan mental, penelitian ini diharapkan dapat memberikan kontribusi dalam pengembangan sistem deteksi konten self-harm berbasis multimodal yang lebih akurat dan kontekstual.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan di atas, maka permasalahan penelitian dirumuskan sebagai berikut:

1. Bagaimana membangun model klasifikasi biner dengan menggunakan CLIP dan ELECTRA secara multimodal untuk mengidentifikasi *self-harm* pada meme secara *multimodal* melalui pendekatan *intermediate fusion*?
2. Bagaimana pengaruh integrasi representasi visual dari CLIP dan representasi tekstual dari ELECTRA melalui skema *intermediate fusion* untuk meningkatkan pemahaman konteks dalam meme, dibandingkan pendekatan unimodal sebagai *baseline*?

3. Bagaimana kinerja model multimodal yang diusulkan dalam mendeteksi meme *self-harm* berdasarkan evaluasi menggunakan *confusion matrix*?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah diuraikan di atas, maka tujuan dari penelitian ini adalah:

1. Mengembangkan model klasifikasi biner berbasis multimodal dengan menggunakanCLIP dan ELECTRA dalam mendeteksi meme yang mengandung indikasi *self-harm* melalui pendekatan *intermediate fusion*.
2. Menganalisis relevansi dan efektivitas integrasi representasi visual dari CLIP dan representasi tekstual dari ELECTRA melalui skema *intermediate fusion* dalam meningkatkan pemahaman konteks pada meme.
3. Mengevaluasi kinerja model multimodal yang diusulkan dalam mendeteksi meme *self-harm* dengan menggunakan metrik evaluasi berbasis *confusion matrix*.

1.4 Batasan Masalah

Batasan masalah dari penelitian adalah sebagai berikut:

1. Penelitian ini hanya membahas meme sebagai konten digital *multimodal* yang terdiri dari gambar dan teks. Penelitian tidak mencakup konten berbentuk video, audio, GIF, atau format *multimodal* lainnya. Pembatasan ini mengikuti karakteristik meme yang membutuhkan pemahaman gabungan antara modalitas visual dan tekstual untuk menangkap makna yang tersirat.
2. Modalitas teks yang digunakan berfokus pada bahasa Inggris karena model pra-latih yang digunakan dalam penelitian ini dilatih pada domain yang sama dalam bahasa tersebut, sehingga hasilnya lebih konsisten.
3. Format gambar yang digunakan dibatasi pada *.jpg/.jpeg*, *.png*, dan *.webp*. Format gambar di luar format tersebut serta konten non-statis (misalnya GIF/video) tidak termasuk dalam ruang lingkup penelitian.
4. Penelitian ini menerapkan skema klasifikasi biner, yaitu *self-harm* dan *non self-harm*. Penelitian tidak mencakup klasifikasi multi-kelas, kategorisasi

tingkat keparahan, maupun penilaian risiko klinis/diagnostik.

5. Definisi operasional kategori ditetapkan sebagai berikut:
   (a) *Self-harm* dalam penelitian ini merujuk pada indikasi atau representasi *self-harm* dalam konten meme (gambar dan teks), bukan pada diagnosis atau kondisi psikologis individu. *Self-harm* didefinisikan sebagai tindakan menyakiti diri yang disengaja, dengan atau tanpa niat bunuh diri, sebagaimana dijelaskan dalam literatur klinis, namun dalam konteks penelitian ini diidentifikasi melalui sinyal multimodal yang muncul pada konten digital.
   (b) Dalam penelitian ini, label *self-harm* diberikan hanya pada meme yang sinyal *self-harm*-nya didukung oleh kedua modalitas, yaitu teks dan visual sama-sama merepresentasikan atau menguatkan tema *self-harm*, sehingga konteksnya tidak bergantung pada satu modalitas saja.
   (c) *Non self-harm* adalah meme yang tidak mengandung indikasi *self-harm* pada teks maupun visual. Meme dengan emosi negatif umum tetap termasuk *non self-harm* selama tidak ada sinyal *self-harm*/keinginan mati.
   (d) Penentuan label dilakukan berdasarkan *annotation guideline* berbasis literatur, sehingga hasil klasifikasi merepresentasikan indikasi risiko dalam konten, bukan kebenaran absolut mengenai niat atau kondisi pembuat konten. Oleh karena itu, kemungkinan subjektivitas interpretasi tetap diakui sebagai bagian dari keterbatasan penelitian.
6. Penelitian ini menggunakan pendekatan penggabungan fitur tingkat menengah (*intermediate fusion*) untuk mengintegrasikan representasi visual dari CLIP dan representasi tekstual dari ELECTRA. Pendekatan ini dipilih karena memungkinkan model untuk mempelajari hubungan semantik lintas modalitas pada level representasi, yang dianggap lebih relevan untuk analisis meme dibandingkan pendekatan *late fusion* atau *early fusion*.
7. Pedoman anotasi (*annotation guideline*) pada penelitian ini disusun berdasarkan studi literatur terkait definisi *self-harm* dan analisis meme multimodal, tanpa validasi oleh ahli atau klinisi. Oleh karena itu, pedoman ini

bersifat operasional dan digunakan khusus dalam konteks penelitian ini, serta menjadi acuan dalam proses pelabelan, termasuk saat pelabelan oleh *Large Language Model* (LLM).

8. Penelitian ini menggunakan pendekatan *weakly supervised learning* dengan pelabelan *ensamble pseudo-labeling* berbasis model/LLM tanpa validasi ahli, sehingga label yang dihasilkan merupakan *weak labels* dan pelatihan model adalah *weakly supervised learning*. Pseudo-labeling dipahami sebagai proses pemberian label pada data tak berlabel menggunakan prediksi model, lalu label tersebut digunakan kembali dalam proses pelatihan [20].. Jika dua model LLM menghasilkan label yang sama, label tersebut digunakan sebagai *pseudo-label*. Jika keduanya berbeda, pelabelan dilakukan secara manual oleh peneliti (dengan pedoman yang sama) sehingga tidak semua data bergantung sepenuhnya pada prediksi model LLM yang digunakan.
9. *Dataset* penelitian diperoleh dari
   (a) Dataset primer yang dikumpulkan secara manual dari sumber konten digital, yaitu platform media sosial yang relevan dengan tema *self-harm*, dan rekayasa dataset meme.
   (b) Dataset sekunder yang diperoleh dari sumber terbuka sebagai data tambahan untuk pelatihan model. Sumber terbuka ini dipilih untuk memperluas label *non self-harm* sehingga label *self-harm* tetap menjadi minoritas dalam *dataset*, sesuai dengan karakteristik alami dari fenomena tersebut di ruang digital.
10. Penelitian ini dibatasi pada pengembangan dan evaluasi model dalam konteks eksperimen *dataset* penelitian, dan tidak membahas implementasi kebijakan moderasi platform maupun penanganan pengguna secara individual.
11. Evaluasi kinerja model dilakukan menggunakan metrik berbasis *confusion matrix* untuk mengukur kemampuan model dalam mendeteksi meme *self-harm*, tanpa membahas aspek interpretabilitas model atau analisis kesalahan secara mendalam.

1.5 Manfaat Penelitian

Berikut adalah manfaat yang diharapkan dari penelitian ini:

1. Menghasilkan model klasifikasi multimodal berbasis *CLIP* dan *ELECTRA* dengan pendekatan *intermediate fusion* yang mampu memahami hubungan antara teks dan gambar pada meme, sehingga meningkatkan kemampuan deteksi konten *self-harm* dibandingkan pendekatan unimodal.
2. Menyediakan kerangka metodologi dalam pengembangan model deteksi meme berisiko berbasis multimodal yang dapat dijadikan acuan untuk penelitian lanjutan pada domain serupa, seperti *cyberbullying*, *hate speech*, atau konten berbahaya lainnya.
3. Menghasilkan dataset meme *self-harm* berbasis multimodal (teks dan gambar) melalui pendekatan *pseudo-labeling* untuk mengatasi keterbatasan dataset publik pada domain ini, yang telah diidentifikasi sebagai salah satu tantangan utama dalam penelitian *harmful memes*, serta menyediakan dataset yang dapat menjadi acuan bagi penelitian selanjutnya [5].
4. Menyediakan sumber daya penelitian berupa dataset, model, dan pipeline eksperimen yang terdokumentasi, sehingga memungkinkan replikasi, evaluasi ulang, dan pengembangan lebih lanjut oleh peneliti lain.

1.6 Sistematika Penulisan

Sistematika penulisan berisi pembahasan apa yang akan ditulis disetiap Bab. Sistematika pada umumnya berupa paragraf yang setiap paragraf mencerminkan bahasan setiap Bab.

1.6.1 Bab I Pendahuluan

Bab ini memuat penjelasan mengenai latar belakang yang menjadi dasar penelitian ini. Latar belakang tersebut menjelaskan tentang konteks permasalahan yang dihadapi dan urgensi penelitian yang dilakukan. Selanjutnya, disajikan rumusan masalah yang merupakan identifikasi masalah yang ingin diselesaikan melalui penelitian ini. Peneliti juga menguraikan tujuan dari penelitian, batasan ruang lingkup penelitian agar fokus, serta manfaat yang diharapkan dari penelitian

ini baik untuk pengembangan ilmu pengetahuan maupun untuk praktik di lapangan. Pada bagian ini juga dijelaskan sistematika penulisan yang memuat susunan dan isi tiap bab yang ada dalam tugas akhir ini.

1.6.2 Bab II Tinjauan Pustaka

Bab ini menyajikan kajian teori yang relevan dengan topik penelitian. Tinjauan pustaka mencakup penelitian terdahulu yang memiliki hubungan dengan penelitian ini, serta teori-teori yang mendasari pokok bahasan penelitian. Dalam bagian ini, peneliti akan mengkaji berbagai literatur yang dapat memberikan pemahaman lebih mendalam terkait topik yang diteliti.

1.6.3 Bab III Metodologi Penelitian

Bab ini berisi penjelasan rinci mengenai metode yang digunakan dalam penelitian ini. Selanjutnya, dijelaskan pula rancangan pengujian yang akan dilakukan untuk mengukur dan menganalisis hasil penelitian.

1.6.4 Bab IV Hasil dan Pembahasan

Bab ini memaparkan hasil yang diperoleh dari implementasi dan pengujian yang telah dilakukan dalam penelitian. Peneliti juga menganalisis dan mengevaluasi hasil yang diperoleh untuk memberikan gambaran yang jelas tentang pencapaian tujuan penelitian.

1.6.5 Bab V Kesimpulan dan Saran

Bab ini memaparkan kesimpulan yang diambil berdasarkan hasil analisis dan pembahasan yang telah dilakukan. Peneliti merangkum temuan utama dari penelitian ini dan memberikan saran untuk penelitian lebih lanjut. Saran tersebut bisa mencakup perbaikan atau pengembangan lebih lanjut dari penelitian yang dilakukan, serta rekomendasi yang dapat diambil untuk implementasi di masa depan.

BAB II
TINJAUAN PUSTAKA

2.1 Tinjauan Pustaka

Tinjauan pustaka berikut memaparkan berbagai penelitian terdahulu yang memiliki relevansi dengan topik yang diteliti serta menjadi landasan utama dalam penyusunan tugas akhir. Kajian ini bertujuan untuk memberikan gambaran mengenai perkembangan penelitian yang berkaitan dengan permasalahan yang diteliti. Selain itu, tinjauan pustaka juga membantu dalam mengidentifikasi kelebihan dan keterbatasan dari penelitian sebelumnya. Adapun penelitian-penelitian yang dijadikan sebagai acuan utama diuraikan sebagai berikut.

Penelitian yang dilakukan oleh Sharma et al. pada tahun 2022 menyajikan sebuah studi tinjauan *(survey)* yang mengkaji perkembangan penelitian terkait meme berbahaya beserta tantangan yang dihadapi dalam bidang tersebut. Melalui analisis terhadap berbagai penelitian sebelumnya, penulis mengidentifikasi bahwa sebagian besar studi masih berfokus pada kategori meme tertentu, sementara jenis meme lain seperti yang berkaitan dengan *self-harm* belum banyak diteliti. Temuan utama dari penelitian ini menunjukkan bahwa keterbatasan ketersediaan dataset menjadi faktor utama yang menghambat eksplorasi pada kategori tersebut [5]. Oleh karena itu, penelitian ini menegaskan adanya kesenjangan riset yang signifikan, khususnya dalam penyediaan dataset dan pengembangan metode untuk analisis meme *self-harm*.

Penelitian yang dilakukan oleh Pramanick et al. pada tahun 2021 memperkenalkan MOMENTA, yaitu sebuah kerangka kerja multimodal yang dirancang untuk mendeteksi meme berbahaya sekaligus mengidentifikasi target yang disasar. Metode yang diusulkan menggabungkan informasi global melalui representasi gabungan gambar dan teks, serta informasi lokal yang diperoleh dari deteksi objek, atribut visual, dan ekstraksi teks menggunakan OCR (*Optical Character Recognition*), sehingga mampu menangkap konteks meme secara lebih

komprehensif. Hasil eksperimen menunjukkan bahwa MOMENTA mampu mengungguli berbagai model pembanding pada tugas deteksi meme berbahaya dan identifikasi target, dengan peningkatan performa yang konsisten [21]. Meskipun penelitian ini berfokus pada kategori *hate speech* dan propaganda, pendekatan multimodal yang digunakan menunjukkan relevansi untuk analisis meme *self-harm*, sekaligus mengindikasikan adanya peluang pengembangan lebih lanjut pada kategori tersebut yang masih belum banyak diteliti.

Penelitian yang dilakukan oleh Kumar dan Nandakumar pada tahun 2022 mengusulkan Hate-CLIPper, yaitu model klasifikasi meme berbasis multimodal yang memanfaatkan representasi dari CLIP serta interaksi eksplisit antara fitur visual dan teks. Penelitian ini dilatarbelakangi oleh permasalahan bahwa informasi pada meme tidak dapat dipahami secara terpisah antara gambar dan teks, sehingga diperlukan pemodelan hubungan lintas-modal yang lebih efektif . Untuk mengatasi hal tersebut, penulis memperkenalkan *Feature Interaction Matrix* (FIM) yang dibangun dari interaksi antara *embedding* visual dan teks, sehingga mampu menangkap hubungan semantik secara lebih mendalam dibandingkan pendekatan konvensional . Hasil eksperimen menunjukkan bahwa model yang diusulkan mencapai performa state-of-the-art dengan nilai AUROC sebesar 85,8% pada dataset Hateful Memes Challenge, bahkan melampaui performa manusia, serta menunjukkan kemampuan generalisasi pada dataset lain [22]. Meskipun penelitian ini berfokus pada deteksi hate speech, pendekatan berbasis interaksi fitur lintas-modal yang diusulkan memberikan dasar yang kuat untuk menangkap makna implisit pada meme, sehingga membuka peluang penerapan pada analisis meme *self-harm* yang masih terbatas dalam penelitian sebelumnya.

Penelitian yang dilakukan oleh Shah *et al.* pada tahun 2024 mengusulkan *MemeCLIP*, yaitu sebuah framework multimodal yang memanfaatkan representasi *CLIP* untuk melakukan klasifikasi meme secara multiaspek. Penelitian ini dilatarbelakangi oleh keterbatasan studi sebelumnya yang umumnya hanya berfokus pada satu aspek, seperti *hate speech*, sehingga belum mampu menangkap kompleksitas makna dalam meme yang bersifat multi-dimensi. Untuk mengatasi hal tersebut, penulis memperkenalkan dataset baru bernama *PrideMM* yang terdiri dari

5.063 meme terkait gerakan *LGBTQ+* dengan beberapa label sekaligus, yaitu *hate*, *target*, *stance*, dan *humor*, serta mengembangkan pendekatan berbasis *CLIP* yang diadaptasi untuk pembelajaran *downstream*. Hasil eksperimen menunjukkan bahwa *MemeCLIP* mampu mengungguli berbagai metode sebelumnya pada beberapa dataset nyata, serta menunjukkan performa yang kompetitif ketika dibandingkan dengan pendekatan *zero-shot* berbasis *GPT-4* [14]. Temuan ini menegaskan pentingnya pendekatan multiaspek dalam analisis meme, sekaligus menunjukkan adanya peluang penelitian lebih lanjut untuk memasukkan kategori lain seperti *self-harm* yang belum tercakup dalam skema klasifikasi tersebut.

Penelitian yang dilakukan oleh Lian *et al.* pada tahun 2023 mengevaluasi kemampuan model multimodal *GPT-4V* dalam tugas pengenalan emosi secara luas melalui pendekatan *zero-shot*. Dalam penelitian tersebut, penulis menyusun 21 dataset *benchmark* yang mencakup berbagai tugas emosi, seperti analisis sentimen pada gambar dan teks, serta pengenalan ekspresi wajah dalam kondisi statis maupun dinamis. Hasil eksperimen menunjukkan bahwa *GPT-4V* memiliki kemampuan yang kuat dalam memahami informasi visual dan emosional, serta mampu memanfaatkan petunjuk multimodal dan konteks temporal, meskipun masih memiliki keterbatasan dalam mengenali ekspresi mikro yang sangat spesifik [23]. Temuan ini menunjukkan potensi *Large Multimodal Models* sebagai alat anotasi otomatis tanpa memerlukan pelatihan tambahan, sehingga relevan untuk mengatasi keterbatasan dataset pada penelitian meme *self-harm* melalui pendekatan anotasi berbasis model multimodal.

Penelitian-penelitian yang menjadi referensi penulis dijabarkan pada Tabel 2.1 di bawah ini.

Tabel 2.1 Literasi Penelitian Terdahulu

No.	Peneliti (Tahun)	Judul	Permasalahan	Metode	Hasil
1.	Sharma *et al.* (2022) [5]	*Detecting and Understanding Harmful Memes: A Survey*	Minimnya studi komprehensif meme berbahaya (termasuk *self-harm*)	Survei literatur dan klasifikasi tipologi meme berbahaya	Menyoroti gap penting: meme *self-harm* belum diteliti dan sulit karena data tidak tersedia
2.	Pramanick *et al.* (2021) [21]	*MOMENTA: Multimodal Framework for Harmful Memes*	Deteksi meme toksik dan targetnya (menggabungkan konteks visual + teks)	Framework multimodal MOMENTA: gabungkan fitur global (CLIP) dan lokal (wajah/objek via VGG-19 + OCR) dengan *attention fusion*	Kinerja unggul: akurasi +1,3–2,6 poin dibanding baseline (dua tugas: deteksi bahaya dan identifikasi target)

No.	Peneliti (Tahun)	Judul	Permasalahan	Metode	Hasil
3.	Kumar & Nandakumar (2022) [22]	*Hate-CLIPper: Multimodal Hateful Meme Classification...*	Klasifikasi meme kebencian dengan interaksi fitur halus	Arsitektur Hate-CLIPper: gunakan *embedding* CLIP (gambar dan teks) dan *Feature Interaction Matrix* (*outer-product*)	AUROC 85,8% pada dataset Hateful Memes (melampaui manusia 82,65%); generalis di beberapa dataset meme lainnya
4.	Shah *et al.* (2024) [14]	*MemeCLIP: CLIP for Multimodal Meme Classification*	Klasifikasi meme multimodal dengan label multiperkara (*hate*, *target*, *humor*)	Dataset baru PrideMM (5.063 meme LGBT) dengan label *hate/target/stance/humor*; melatih CLIP dengan adapter ringan	MemeCLIP unggul pada dua dataset nyata (PrideMM dan HarMeme) dibanding metode sebelumnya; analisis kekurangan model dan GPT-4

No.	Peneliti (Tahun)	Judul	Permasalahan	Metode	Hasil
5.	Lian *et al.* (2023) [23]	*GPT-4V with Emotion: Zero-shot Benchmark for Emotion Recognition*	Evaluasi GPT-4V di tugas pengenalan emosi multimodal	Uji *zero-shot* GPT-4V pada 21 dataset emosi (visual + teks) termasuk analisis sentimen dan ekspresi wajah	GPT-4V kuat di tugas emosi umum dan integrasi multimodal baik, namun lemah mengenali ekspresi mikro khusus

2.2 Dasar Teori

Berikut adalah penjelasan mengenai teori-teori yang menjadi landasan dalam penelitian ini, termasuk konsep-konsep utama seperti *self-harm*, meme, multimodal *deep learning*, klasifikasi *fusion*, *computer vision*, *natural language processing*, *deep learning*, *transformer*, *Contrastive Language-Image Pre-training* (CLIP) dan *Efficiently and Encoder that Classifies Token Replacements Accurately* (ELECTRA). Penjelasan ini bertujuan untuk memberikan pemahaman yang mendalam mengenai konsep-konsep tersebut serta bagaimana mereka saling terkait dalam konteks penelitian ini.

2.2.1 *Self-Harm*

Self-harm atau perilaku menyakiti diri sendiri merupakan tindakan yang dilakukan seseorang untuk melukai tubuhnya secara sengaja, baik dengan maupun tanpa niat untuk mengakhiri hidup. Organisasi Kesehatan Dunia (WHO) mendefinisikan *self-harm* sebagai *"intentional self-inflicted injury, with or without suicidal intent"* [24]. Dalam ranah psikiatri, *Diagnostic and Statistical Manual of Mental Disorders* edisi kelima (DSM-5) membedakan antara *non-suicidal self-injury* (NSSI), yaitu perilaku menyakiti diri tanpa niat bunuh diri yang setidaknya terjadi selama lima hari dalam setahun, dengan *suicidal behavior* yang berorientasi pada keinginan mengakhiri hidup [25]. Self-harm banyak dikaitkan dengan kondisi psikologis seperti depresi, kecemasan, dan kesulitan regulasi emosi.

Perkembangan media sosial memperluas cara individu mengekspresikan pikiran atau perasaan terkait self-harm. Penelitian menunjukkan bahwa konten *self-harm* di platform digital seperti Instagram, TikTok, dan Reddit sering muncul dalam bentuk teks, gambar, atau kombinasi keduanya, dan dapat menjadi indikator risiko ideasi bunuh diri maupun NSSI pada remaja dan dewasa muda [26]. Paparan konten tersebut dapat meningkatkan risiko perilaku, normalisasi self-harm, serta perburukan kondisi mental pengguna yang rentan. Bentuk ekspresi self-harm di media sosial sering kali bersifat implisit melalui humor gelap, metafora visual, atau ungkapan ironi, sehingga sulit diidentifikasi oleh sistem deteksi sederhana [5]. Meme self-harm biasanya memadukan elemen visual dan teks secara multimodal

sehingga maknanya muncul dari hubungan antara kedua modalitas tersebut, bukan dari salah satu modalitas secara terpisah. Penelitian menunjukkan bahwa meme bertema self-harm sering mengandung humor gelap, sarkasme, atau representasi simbolik dari rasa sakit emosional, yang membuatnya menantang untuk ditangkap oleh model berbasis unimodal [13]. Oleh karena itu, pendekatan *multimodal deep learning* diperlukan untuk memahami interaksi visual-linguistik pada meme dan mengidentifikasi konten *self-harm* secara lebih akurat.

2.2.2 Meme

Meme adalah bentuk pesan digital yang menyebar secara cepat melalui internet dan media sosial, dan biasanya terdiri atas kombinasi elemen visual (gambar) serta teks yang membentuk makna tertentu dalam konteks budaya. Secara etimologis, istilah *meme* pertama kali diperkenalkan oleh Richard Dawkins (1976) sebagai "unit budaya yang menyebar melalui imitasi," namun dalam konteks modern, meme berkembang menjadi fenomena visual linguistik yang merepresentasikan humor, kritik sosial, opini, atau emosi melalui struktur multimodal yang ringkas. Penelitian dalam bidang komunikasi digital menunjukkan bahwa makna meme tidak hanya berasal dari gambar atau teks secara terpisah, tetapi dari hubungan interaktif antara keduanya, termasuk elemen seperti ironi, metafora visual, sarkasme, dan referensi budaya (*cultural references*) yang bersifat kontekstual [4]. Kompleksitas ini menjadikan meme sebagai bentuk komunikasi multimodal yang sulit dipahami oleh model berbasis unimodal, karena penafsirannya sering bergantung pada kemampuan untuk menangkap keterkaitan antara modalitas visual dan linguistik. Oleh sebab itu, dalam deteksi meme berbahaya seperti *self-harm* atau *hate speech* diperlukan pendekatan *multimodal deep learning* yang mampu memahami hubungan lintas-modal (*cross-modal semantics*) antara teks dan gambar.

2.2.3 *Multimodal Deep learning*

Multimodal *deep learning* adalah pendekatan pembelajaran mesin yang memanfaatkan *deep neural networks* untuk mengintegrasikan berbagai modalitas data, seperti teks, gambar, audio, atau video, sehingga model mampu memahami

informasi secara lebih kontekstual [27]. Modalitas merujuk pada jenis data yang berbeda, gambar membawa informasi visual spasial, teks membawa informasi semantik dan linguistik, sedangkan audio atau video menangkap informasi temporal [28]. Dalam multimodal *deep learning*, setiap modalitas diproses oleh *encoder* neural network tersendiri untuk menghasilkan representasi (*embedding*) yang memodelkan karakteristik modalitas tersebut secara mendalam. *Embedding* dari berbagai modalitas kemudian digabung melalui mekanisme *fusion* agar model dapat menangkap hubungan lintas-modal (*cross-modal relationships*) yang kompleks, sehingga memungkinkan penggabungan keunggulan tiap modalitas dan mengatasi keterbatasan ketika hanya menggunakan satu modalitas. Pendekatan ini pertama kali distandardisasi oleh Ngiam et al. pada tahun, yang menunjukkan bahwa jaringan neural yang dilatih dengan data multimodal mampu mempelajari representasi bersama yang lebih kuat dibandingkan representasi unimodal [27]. Dalam konteks penelitian ini, pendekatan multimodal menjadi penting karena meme self-harm sering kali menyampaikan makna melalui hubungan implisit antara teks dan gambar.

2.2.4 Klasifikasi *Fusion* dalam *Multimodal Deep learning*

Salah satu aspek kunci dari *multimodal deep learning* adalah bagaimana modalitas berbeda digabung, yaitu melalui proses *fusion*. Berdasarkan kapan dan bagaimana penggabungan dilakukan, teknik *fusion* secara umum dapat diklasifikasikan menjadi empat kategori utama, yaitu *early fusion*, *intermediate fusion*, *late fusion*, dan *hybrid fusion*. Dalam penelitian ini, digunakan pendekatan intermediate fusion karena mampu menggabungkan representasi fitur visual dan tekstual pada level embedding, sehingga memungkinkan model menangkap hubungan semantik lintas-modalitas secara lebih efektif.

2.2.4.1 *Early Fusion*

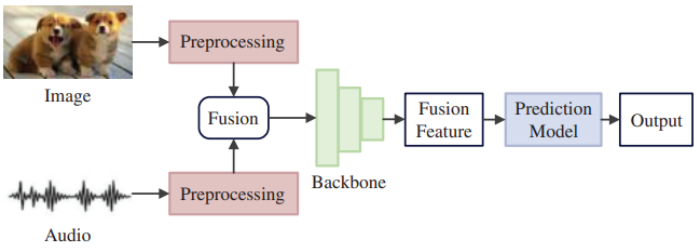

Gambar 2.1 Contoh Early Fusion [29]

Pada pendekatan ini, modalitas digabungkan pada tingkat input sebelum proses *encoding*. Contohnya pada Gambar 2.1, data gambar dan audio digabung menjadi satu representasi gabungan yang kemudian diberikan ke neural network. Early fusion memungkinkan model mempelajari interaksi antar-modalitas dari tahap awal, tetapi menghadapi tantangan signifikan karena heterogenitas struktur data (misalnya perbedaan dimensi, skala, dan format) yang dapat menyulitkan integrasi langsung [30].

2.2.4.2 *Intermediate Fusion*

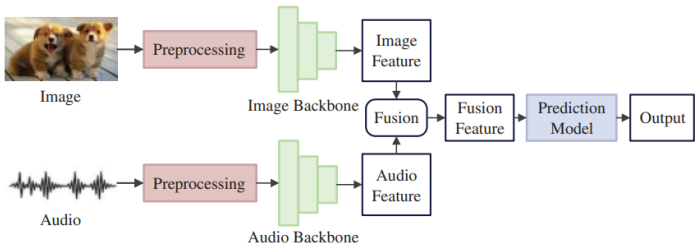

Gambar 2.2 Contoh Intermediate Fusion [29]

Pada Gambar 2.2, setiap modalitas terlebih dahulu diproses oleh *encoder* masing-masing untuk menghasilkan *embedding* atau fitur spesifik modalitas. Setelah itu, embedding dari berbagai modalitas digabung misalnya melalui *concatenation*, *projection*, *pooling*, atau mekanisme *fusion* lanjutan sebelum diteruskan ke lapisan prediksi. Pendekatan ini menawarkan keseimbangan antara kemampuan merepresentasikan keunikan tiap modalitas dan mempelajari hubungan lintas-

modalitas, sehingga banyak digunakan pada model modern, termasuk sistem vision language [29].

2.2.4.3 *Late Fusion*

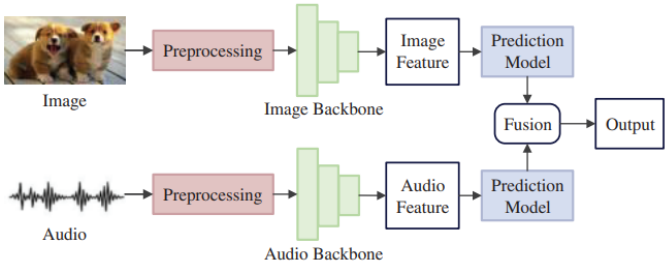

Gambar 2.3 Contoh Late Fusion [29]

Pada Gambar 2.3 setiap modalitas diproses secara independen hingga menghasilkan prediksi masing-masing, seperti probabilitas atau skor klasifikasi. Prediksi tersebut kemudian digabung menggunakan metode seperti *weighted sum*, *voting*, atau *averaging* untuk memperoleh prediksi akhir. Late fusion efektif ketika modalitas relatif independen dan prediksi masing-masing sudah cukup kuat, namun kurang mampu menangkap interaksi semantik yang mendalam antar-modalitas [29].

2.2.4.4 *Hybrid Fusion*

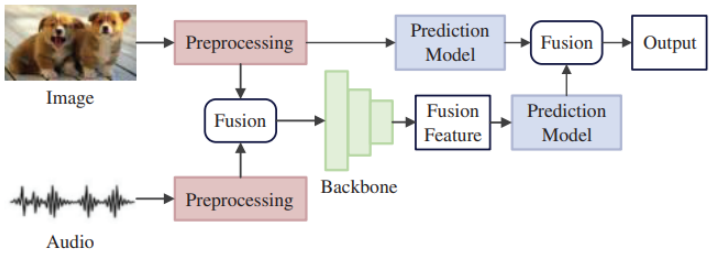

Gambar 2.4 Contoh *Hybrid Fusion* [29]

Hybrid fusion menggabungkan dua atau lebih strategi fusion, misalnya mengombinasikan *feature-level fusion* dan *decision-level fusion*, atau menggabungkan embedding dengan mekanisme *attention* sekaligus memanfaatkan penggabungan skor prediksi. Pada Gambar 2.4, hybrid fusion banyak digunakan

pada aplikasi multimodal yang kompleks karena mampu memanfaatkan kelebihan beragam strategi sekaligus mengatasi keterbatasan masing-masing [29].

Dalam praktiknya, pemilihan teknik *fusion* sangat bergantung pada karakteristik data, tujuan aplikasi, serta kompleksitas model yang diinginkan. Pendekatan *intermediate fusion* sering kali menjadi pilihan populer karena fleksibilitas dan kemampuannya dalam menangkap hubungan lintas-modalitas secara efektif.

2.2.5 *Computer Vision*

Computer vision merupakan bidang dalam kecerdasan buatan yang berfokus pada bagaimana mesin dapat memahami dan menafsirkan informasi visual dari gambar maupun video melalui representasi numerik yang terstruktur [31]. Proses komputasional ini mencakup tahapan seperti ekstraksi fitur, deteksi pola, dan pemahaman objek melalui algoritma yang mempelajari hubungan spasial maupun semantik di dalam citra. Pendekatan modern dalam *computer vision* didominasi oleh *deep learning*, khususnya *Convolutional Neural Networks* (CNN), yang mampu mempelajari fitur visual secara hierarkis mulai dari tepi (*low-level features*) hingga representasi abstrak (*high-level features*) melalui pembelajaran berbasis data [32]. Perkembangan lebih lanjut melahirkan *Vision Transformer* (ViT), arsitektur berbasis mekanisme *self-attention* yang memecah gambar dalam bentuk *patch* dan memprosesnya seperti token dalam NLP, sehingga menghasilkan performa kompetitif pada skala data besar [33]. Dengan kemampuan menghasilkan *embedding* visual yang kaya semantik, *computer vision* menjadi fondasi penting dalam berbagai aplikasi, termasuk klasifikasi gambar, deteksi objek, dan pemahaman multimodal seperti pada model *vision-language*.

2.2.6 *Natural Language Processing* (NLP)

NLP merupakan cabang kecerdasan buatan yang berfokus pada bagaimana mesin dapat memahami, memproses, dan menghasilkan bahasa manusia melalui representasi matematis yang terstruktur **ibm˙nlp**. NLP modern bertumpu pada pembelajaran representasi *(representation learning)*, dimana teks diubah menjadi *embedding* yang mampu menangkap konteks semantik maupun sintaksis.

Pergeseran besar dalam NLP terjadi dengan hadirnya pendekatan berbasis *deep learning*, yang dimulai dengan penggunaan *recurrent neural networks* (RNN) dan *Long Short-Term Memory* (LSTM), sebelum akhirnya banyak digantikan oleh arsitektur Transformer yang memungkinkan pemodelan konteks panjang melalui mekanisme *self-attention* [34]. Transformer kemudian menjadi fondasi model-model pra-latih (*pre-trained models*) seperti BERT, GPT, dan ELECTRA yang memanfaatkan *pre-training* berskala besar untuk mempelajari pola bahasa secara mendalam, sehingga meningkatkan performa berbagai tugas seperti klasifikasi teks, analisis sentimen, dan pemahaman multimodal [35]. Dengan kemampuan menghasilkan representasi linguistik yang kaya konteks, NLP menjadi komponen penting dalam pemrosesan modalitas teks pada sistem multimodal modern.

2.2.7 *Deep Learning*

Deep learning merupakan pendekatan dalam *machine learning* yang menggunakan jaringan saraf tiruan berlapis banyak *(deep neural networks)* untuk mempelajari pola dan representasi data secara otomatis melalui proses hierarkis. Berbeda dari metode pembelajaran tradisional yang mengandalkan rekayasa fitur manual, *deep learning* memungkinkan ekstraksi fitur kompleks secara langsung dari data mentah menggunakan transformasi non-linear yang dioptimalkan melalui algoritma *backpropagation* [32]. Konsep representasi berlapis inilah yang membuat *deep learning* unggul dalam menangani data dengan skala besar dengan struktur yang beragam seperti teks dan gambar karena model dapat mempelajari fitur tingkat rendah hingga abstraksi tingkat tinggi secara bertahap [36]. Dengan fleksibilitas dan kemampuan generalisasi yang kuat, *deep learning* telah menjadi fondasi utama pengembangan berbagai arsitektur modern dalam bidang *computer vision* dan pemrosesan bahasa alami. Salah satu arsitektur *deep learning* yang banyak digunakan dalam pemrosesan data sekuensial seperti teks adalah Transformer.

2.2.8 Transformer

Transformer merupakan salah satu arsitektur *deep learning* yang diperkenalkan oleh Vaswani et al. pada tahun 2017 dan menjadi dasar bagi berbagai model

bahasa dan multimodal modern. Transformer terdiri dari beberapa layer encoder yang disusun secara berulang. Setiap layer terdiri dari dua komponen utama, yaitu *multi-head self-attention* untuk menangkap hubungan antar token, serta *feed-forward network* untuk memproses representasi fitur. Selain itu, digunakan *residual connection* dan *layer normalization* untuk menjaga stabilitas pelatihan model.

Salah satu komponen penting dalam Transformer adalah *multi-head attention*, yang memungkinkan model untuk memproses informasi dari berbagai subruang representasi secara paralel. Setiap token direpresentasikan sebagai vektor, kemudian dihitung nilai *attention* berdasarkan interaksi antara *query (Q)*, *key (K)*, dan *value (V)*. Proses ini menggunakan rumus *Scaled Dot-Product Attention* yang dihitung sebagai berikut:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Rumus 2.1 *Scaled Dot-Product Attention*

Dimana d_k adalah dimensi dari *key* yang digunakan untuk menstabilkan nilai *dot-product*. Mekanisme ini memungkinkan model untuk menangkap dependensi jangka panjang secara efisien. Selain itu, *multi-head attention* memungkinkan model untuk memproses informasi dari berbagai subruang representasi, yang mendukung pengolahan informasi dalam skala besar dan memungkinkan penanganan konteks yang lebih kompleks.

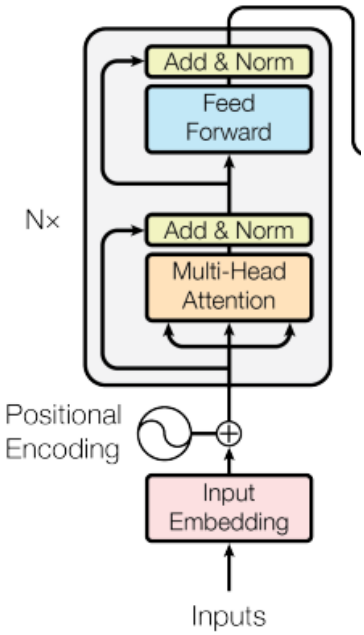

Gambar 2.5 Arsitektur Transformer dengan Encoder [37]

Gambar 2.5 menunjukkan arsitektur Transformer dengan encoder yang fokus pada bagian *input embedding*. Proses dimulai dengan input yang berupa urutan token, yang kemudian diproses menjadi *input embedding*. *Input embedding* mengubah token-token dalam urutan menjadi vektor representasi yang dapat diproses oleh model. Vektor-vektor ini kemudian diperkaya dengan *positional encoding* untuk mempertahankan informasi urutan input, yang sangat penting dalam model Transformer yang tidak bergantung pada urutan sekuensial. Gambar ini menggambarkan bagaimana *input embedding* berfungsi sebagai representasi awal bagi setiap token yang masuk, dan bagaimana *embedding* ini bekerja bersama dengan komponen lain seperti *multi-head attention* untuk menghasilkan representasi yang lebih kompleks dalam proses pemodelan [37]. Kemampuan Transformer dalam menangkap hubungan konteks yang kompleks ini menjadikannya fondasi utama dalam pengembangan model multimodal dan model bahasa modern. Perkembangan arsitektur Transformer ini kemudian mendorong lahirnya berbagai model multimodal yang mampu mengintegrasikan informasi visual dan tekstual, salah satunya adalah CLIP.

2.2.9 *Contrastive Language-Image Pre-training* (CLIP)

CLIP (*Contrastive Language–Image Pre-training*) adalah model vision–language yang dikembangkan oleh OpenAI untuk mempelajari keterkaitan semantik antara gambar dan teks melalui pembelajaran kontrasif berskala besar. CLIP terdiri atas dua *encoder* terpisah, yaitu *image encoder* berbasis Vision Transformer (ViT), serta *text encoder* berbasis Transformer yang keduanya memetakan gambar dan teks ke dalam ruang *embedding* yang sama. Selama pelatihan, CLIP memanfaatkan jutaan pasangan gambar–teks dari internet untuk mempelajari *alignment* antar-modalitas dengan menempatkan pasangan yang cocok semakin dekat dan pasangan tidak cocok semakin jauh dalam ruang vektor. Mekanisme pembelajaran ini diformalkan menggunakan *contrastive loss* (InfoNCE), yang dirumuskan sebagai:

$$\mathcal{L} = -\frac{1}{2N}\sum_{i=1}^{N}\left[\log\frac{\exp(\cos(f_I(L_i), f_T(T_i))/\tau)}{\sum_{j=1}^{N}\exp(\cos(f_I(L_i), f_T(T_j))/\tau)} + \log\frac{\exp(\cos(f_T(T_i), f_I(L_i))/\tau)}{\sum_{j=1}^{N}\exp(\cos(f_T(T_i), f_I(L_j))/\tau)}\right]$$

Rumus 2.2 Contrastive Loss (InfoNCE) pada CLIP

Di mana f_I dan f_T adalah encoder gambar dan teks, cos adalah fungsi kesamaan kosinus, dan τ adalah parameter temperatur. Melalui pendekatan ini, CLIP mampu menghasilkan representasi multimodal yang kaya konteks dan sangat efektif untuk berbagai tugas *downstream* tanpa perlu *fine-tuning*, termasuk klasifikasi multimodal, analisis meme, serta deteksi konten berisiko.

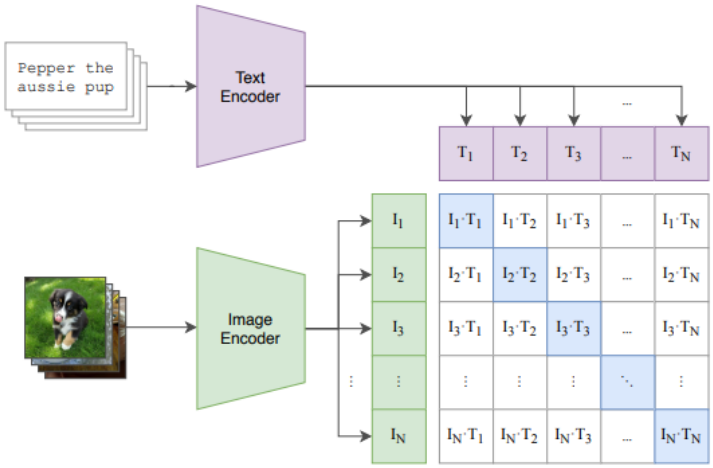

Gambar 2.6 Arsitektur CLIP [38]

Gambar 2.6 di atas mengilustrasikan arsitektur model CLIP yang menerapkan mekanisme dual-encoder untuk mempelajari representasi visual dan tekstual secara bersamaan. Dalam proses ini, *text encoder* dan *image encoder* bekerja secara paralel mengubah sekumpulan input gambar dan teks menjadi vektor fitur *(embedding)* dalam ruang dimensi yang sama. Setiap pasangan gambar-teks yang sesuai dipetakan ke vektor yang berdekatan, sementara pasangan yang tidak sesuai dipisahkan lebih jauh, melalui optimasi fungsi InfoNCE yang memaksimalkan kesamaan kosinus antar *embedding* [38]. Dalam penelitian ini, CLIP digunakan sebagai *image encoder* untuk mengekstraksi fitur visual dari meme, karena kemampuannya dalam memahami representasi visual yang selaras dengan konteks semantik. Selain digunakan dalam model multimodal seperti CLIP, arsitektur Transformer juga menjadi dasar bagi berbagai model bahasa modern yang digunakan untuk memproses teks secara lebih mendalam. Salah satu model tersebut adalah ELECTRA.

2.2.10 *Efficiently Learning an Encoder that Classifies Token Replacements Accurately* (ELECTRA)

ELECTRA (*Efficiently Learning an Encoder that Classifies Token Replacements Accurately*) merupakan model pra-latih berbasis arsitektur *Transformer* yang diperkenalkan sebagai alternatif yang lebih efisien dibandingkan pendekatan *Masked Language Modeling* (MLM) seperti pada BERT. Berbeda dengan MLM yang hanya

mempelajari representasi dari token yang di-*masking*, ELECTRA menggunakan pendekatan diskriminatif yang disebut *Replaced Token Detection* (RTD), di mana model dilatih untuk membedakan apakah suatu token dalam urutan merupakan token asli atau hasil penggantian oleh model *generator* [18].

Arsitektur ELECTRA terdiri dari dua komponen utama, yaitu *generator* dan *discriminator*. *Generator* bertugas menghasilkan token pengganti berdasarkan skema MLM dalam skala kecil, sedangkan *discriminator* berfungsi untuk mengevaluasi setiap token dalam urutan dan menentukan apakah token tersebut merupakan token asli atau hasil substitusi. Dengan pendekatan ini, proses pembelajaran terjadi pada seluruh token dalam satu urutan, tidak terbatas hanya pada token tertentu seperti pada MLM.

Secara formal, proses pelatihan ELECTRA dimodelkan melalui fungsi *Replaced Token Detection* (RTD) *loss* sebagai berikut:

$$\mathcal{L}_{\text{RTD}} = -\sum_{i=1}^{n} \left[y_i \log D(x_i) + (1 - y_i) \log \left(1 - D(x_i)\right) \right]$$

Rumus 2.3 *Replaced Token Detection* (RTD) *Loss* pada ELECTRA

dengan $y_i = 1$ jika token merupakan token asli dan $y_i = 0$ jika token merupakan hasil penggantian, serta $D(x_i)$ merupakan probabilitas bahwa token tersebut adalah token asli. Fungsi *loss* ini mendorong model untuk mempelajari representasi kontekstual yang mampu membedakan distribusi token asli dan token hasil substitusi secara efektif.

Pendekatan RTD memungkinkan ELECTRA menjadi lebih *sample-efficient* dibandingkan model berbasis MLM, karena seluruh token dalam urutan digunakan dalam proses pembelajaran. Hal ini menjadikan ELECTRA lebih efisien secara komputasi sekaligus mampu menghasilkan representasi linguistik yang lebih kaya dan informatif.

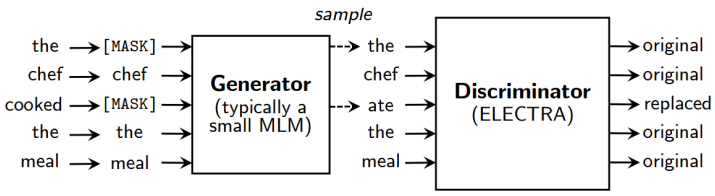

Gambar 2.7 Arsitektur ELECTRA [18]

Gambar 2.7 menunjukkan arsitektur ELECTRA yang terdiri dari interaksi antara *generator* dan *discriminator* dalam proses pelatihan. Melalui mekanisme ini, ELECTRA mampu mempelajari konteks bahasa secara lebih menyeluruh dibandingkan pendekatan pra-latih tradisional.

Dibandingkan dengan BERT, ELECTRA memiliki keunggulan dalam efisiensi pelatihan dan pemanfaatan data, sehingga lebih efektif digunakan pada dataset dengan ukuran terbatas. Selain itu, kemampuan model dalam mengevaluasi setiap token berdasarkan konteks global menjadikannya cocok untuk tugas klasifikasi teks yang membutuhkan pemahaman kontekstual yang mendalam.

Dalam penelitian ini, ELECTRA digunakan sebagai *text encoder* karena kemampuannya dalam menghasilkan representasi teks yang efisien dan kontekstual. Pendekatan RTD memungkinkan model untuk memahami hubungan antar-token secara lebih menyeluruh, yang penting dalam analisis teks pada meme yang sering bersifat implisit, ironi, dan kontekstual.

Selain itu, pemilihan ELECTRA juga didasarkan pada ketersediaan model pra-latih yang telah dilatih pada domain teks yang mengandung sinyal *suicidality* atau *self-harm* [39]. Model pra-latih pada domain spesifik ini memungkinkan representasi tekstual yang lebih relevan terhadap konteks penelitian, karena telah memiliki pemahaman awal terhadap pola bahasa yang berkaitan dengan ekspresi emosional dan indikasi *self-harm*. Dengan demikian, penggunaan model ini diharapkan dapat meningkatkan kemampuan sistem dalam mendeteksi meme *self-harm* secara lebih akurat.

2.2.11 Prapemrosesan Data

Prapemrosesan data adalah tahap penting dalam pipeline analisis data yang bertujuan untuk menyiapkan data mentah agar siap digunakan dalam model. Prapemrosesan data terdiri dari berbagai teknik yang masing-masing dirancang untuk mempersiapkan data dalam bentuk yang sesuai untuk analisis lebih lanjut. Berikut adalah teknik-teknik utama dalam prapemrosesan data.

2.2.11.1 *Resize* Gambar

Resize gambar adalah proses mengubah ukuran gambar untuk memenuhi kebutuhan model yang digunakan. Secara matematis, proses ini melibatkan perhitungan rasio antara dimensi gambar awal dan ukuran target. Jika ukuran gambar asli adalah (W, H) dan gambar yang diinginkan berukuran (W', H'), maka rasio skala untuk lebar dan tinggi adalah sebagai berikut:

$$\text{Scale Factor} = \left(\frac{W'}{W}\right)\left(\frac{H'}{H}\right)$$

Rumus 2.4 Perhitungan Faktor Skala

Resize gambar akan mengubah ukuran citra asli berdasarkan skala ini, yang dapat memperkecil atau memperbesar citra sesuai dengan ukuran yang diinginkan. Dengan memperkecil ukuran gambar, kita dapat mengurangi jumlah parameter yang perlu diproses, meningkatkan efisiensi, dan mengurangi waktu komputasi [40].

2.2.11.2 Normalisasi Gambar

CLIP (*Contrastive Language–Image Pretraining*) menerapkan normalisasi pada dua tahapan krusial dalam arsitekturnya. Pertama, normalisasi input gambar dilakukan dengan menstandarisasi nilai piksel menggunakan *mean* (μ) dan standar deviasi (σ) spesifik agar distribusi data selaras dengan *backbone encoder* visual (seperti ResNet atau ViT). Secara matematis, transformasi ini dapat dituliskan sebagai:

$$x_{norm} = \frac{x - \mu}{\sigma}$$

Rumus 2.5 Normalisasi Input Gambar

dimana x adalah nilai piksel asli dan x_{norm} adalah input yang diteruskan ke jaringan.

Kedua, setelah citra dan teks diproses menjadi *embedding*, CLIP menerapkan *L2-normalization* pada vektor tersebut agar diproyeksikan ke dalam *unit hypersphere*. Jika v adalah vektor fitur keluaran dari *encoder*, maka normalisasi didefinisikan sebagai:

$$v_{norm} = \frac{v}{\|v\|_2} = \frac{v}{\sqrt{\sum_{i=1}^{d} v_i^2}} + h$$

Rumus 2.6 Normalisasi Vektor

Normalisasi vektor pada persamaan Rumus 2.6 ini krusial karena menjadikan operasi *dot product* setara dengan *cosine similarity* dalam perhitungan *loss* kontrastif, sehingga model dapat mempelajari penyelarasan semantik antara teks dan gambar dengan lebih stabil dan konsisten [38].

2.2.11.3 Augmentasi Data

Augmentasi data adalah teknik yang digunakan untuk meningkatkan jumlah dan variasi data pelatihan dengan membuat modifikasi pada data asli. Teknik ini sangat penting dalam konteks pembelajaran mesin, terutama ketika dataset yang tersedia terbatas, karena dapat membantu model untuk belajar lebih baik dan mengurangi risiko *overfitting*. Dalam penelitian ini, augmentasi digunakan untuk meningkatkan variasi data dan membantu model menjadi lebih robust terhadap perubahan visual pada meme. Berikut adalah beberapa teknik augmentasi yang digunakan dalam penelitian ini.

2.2.11.3.1 *Flip*

Flip adalah teknik augmentasi gambar yang digunakan untuk memperbesar variasi data dengan membalik gambar secara horizontal atau vertikal. Ini membantu model menjadi lebih robust terhadap variasi dalam data, seperti orientasi objek [40].

2.2.11.3.2 *Rotation*

Rotasi merupakan teknik augmentasi yang dilakukan dengan memutar gambar ke kanan atau kiri pada suatu sumbu dengan sudut tertentu, biasanya berada pada rentang 1° hingga 359°. Tingkat keamanan *(safety)* dari augmentasi ini sangat ditentukan oleh besar sudut rotasi, karena rotasi yang terlalu ekstrem dapat menyebabkan hilangnya informasi penting pada citra, seperti tepi objek atau struktur yang relevan [41].

2.2.11.3.3 *Color Jitter*

Color Jitter merupakan teknik augmentasi data fotometrik yang berfungsi memodifikasi atribut visual citra meliputi kecerahan, kontras, saturasi, dan rona

secara stokastik tanpa mengubah struktur geometris objek di dalamnya. Penerapan teknik ini bertujuan untuk mensimulasikan variabilitas pencahayaan yang alami terjadi di dunia nyata, sehingga memaksa model untuk mempelajari fitur struktural yang invarian alih-alih bergantung pada bias warna atau intensitas piksel absolut. Mekanisme distorsi warna ini terbukti efektif dalam meningkatkan kemampuan generalisasi model serta memitigasi risiko *overfitting* akibat keterbatasan variasi visual pada data latih [41].

2.2.12 Evaluasi

Evaluasi merupakan tahap penting dalam menilai performa model klasifikasi, terutama pada tugas sensitif seperti deteksi konten self-harm dalam meme. Evaluasi umumnya dilakukan menggunakan *confusion matrix* yang menggambarkan hubungan antara prediksi model dan kondisi sebenarnya. Matriks ini terdiri dari empat komponen, yaitu *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN) [42]. Struktur *confusion matrix* dapat dilihat pada Tabel 2.2.

Tabel 2.2 *Confusion Matrix*

Actual \ Predicted	***Positive***	***Negative***
Positive	TP	FN
Negative	FP	TN

Berdasarkan elemen-elemen tersebut, beberapa metrik evaluasi dapat dihitung. *Accuracy* mengukur proporsi prediksi benar terhadap seluruh sampel, namun sering tidak cukup representatif ketika data tidak seimbang (*imbalanced*) seperti pada deteksi self-harm meme [43]. *Precision* mengukur tingkat ketepatan prediksi kelas positif, sedangkan *Recall* mengukur kemampuan model dalam menangkap seluruh sampel positif. Keduanya penting karena kesalahan *False Negative* (FN) pada deteksi konten self-harm berpotensi membahayakan pengguna. Untuk menyeimbangkan precision dan recall digunakan *F1-score*, yaitu rata-rata harmonik keduanya, yang efektif untuk dataset tidak seimbang [44].

Secara matematis, metrik-metrik evaluasi dirumuskan sebagai berikut:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Rumus 2.7 Perhitungan *Accuracy*

$$Precision = \frac{TP}{TP + FP}$$

Rumus 2.8 Perhitungan *Precision*

$$Recall = \frac{TP}{TP + FN}$$

Rumus 2.9 Perhitungan *Recall*

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Rumus 2.10 Perhitungan *F1-Score*

Kombinasi dari seluruh metrik tersebut memberikan gambaran evaluasi yang lebih komprehensif dibandingkan hanya menggunakan Accuracy saja, terutama karena model untuk deteksi self-harm harus sensitif terhadap kesalahan pada kelas positif. Evaluasi yang menyeluruh ini penting untuk memastikan model tidak hanya akurat secara keseluruhan, tetapi juga efektif dalam mengidentifikasi konten berisiko tinggi.

BAB III
METODE PENELITIAN

3.1 Alur Penelitian

Tahapan penelitian ini diawali dengan proses identifikasi masalah dan studi literatur untuk membangun landasan teori yang kuat. Selanjutnya, dilakukan pengumpulan data, anotasi data dan *pre-processing*. Setelah data siap, penelitian berfokus pada pengembangan model arsitektur multimodal, yang kemudian diuji melalui tahap evaluasi model. Rangkaian penelitian ini ditutup dengan analisis hasil dan pembahasan untuk menarik kesimpulan. Adapun ilustrasi lebih rinci mengenai alur penelitian ini dapat dilihat pada Gambar 3.1.

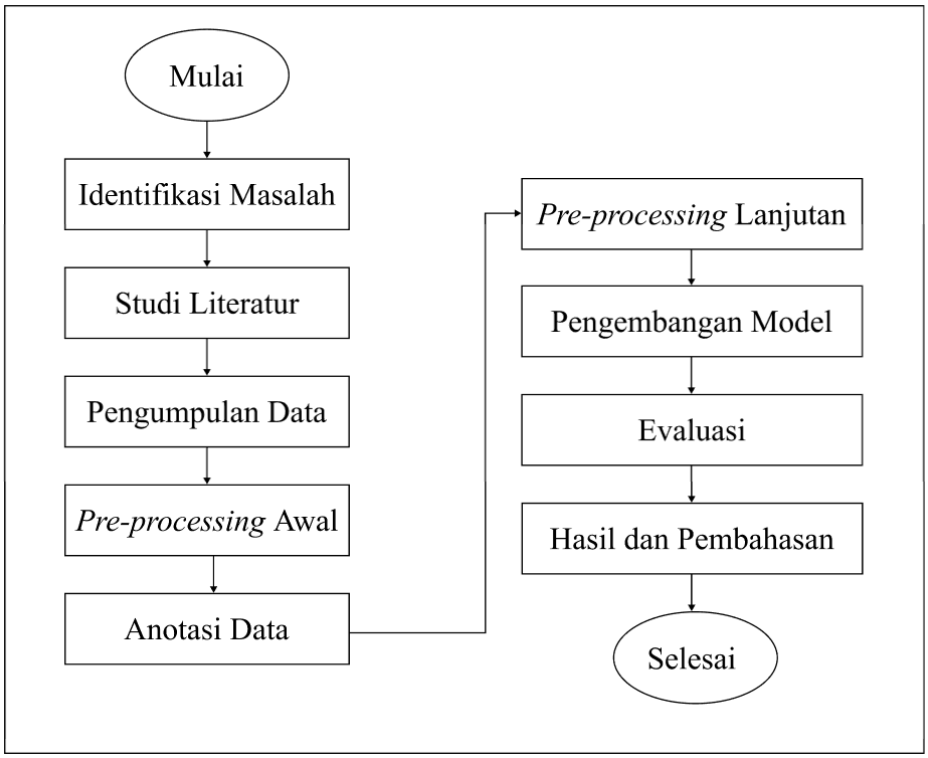

Gambar 3.1 Alur Penelitian

3.2 Penjabaran Langkah Penelitian

Pada alur penelitian yang telah digambarkan dalam diagram alur penelitian pada 3.1, bagian ini menjelaskan secara rinci setiap tahapan yang dilakukan dalam penelitian. Penjabaran ini mencakup proses mulai dari pengumpulan data, anotasi, hingga tahap *pre-processing* sebagai persiapan data. Selanjutnya, dijelaskan tahapan pengembangan model yang meliputi pembagian *dataset*, pelatihan model, serta perancangan arsitektur *multimodal*. Tahap akhir yang diuraikan adalah evaluasi model untuk mengukur kinerja sistem dalam mengidentifikasi meme *self-harm*.

3.2.1 Identifikasi Masalah

Tahap pertama dalam penelitian ini adalah identifikasi masalah melalui studi literatur, yang berfokus pada urgensi memahami meme dengan tema *self-harm* sebagai bentuk konten digital yang memiliki makna implisit. Meme jenis ini sering menyampaikan pesan melalui kombinasi visual dan tekstual, seperti ironi, sarkasme, humor gelap, atau metafora, sehingga indikasi *self-harm* tidak selalu tampak secara eksplisit dan memerlukan analisis *multimodal* untuk dapat dipahami secara utuh. Berdasarkan studi literatur, penelitian terkait deteksi meme berbahaya masih didominasi oleh kategori seperti ujaran kebencian, propaganda, dan konten ofensif, sementara meme dengan nuansa *self-harm* masih sangat terbatas untuk diteliti. Hal ini disebabkan oleh keterbatasan ketersediaan *dataset* publik yang relevan, sebagaimana diungkapkan oleh Sharma *et al.* [5], yang menyatakan bahwa kurangnya *dataset* menjadi hambatan utama dalam pengembangan penelitian pada domain meme berbahaya, khususnya untuk kategori yang kurang tereksplorasi seperti *self-harm*. Kondisi tersebut menunjukkan adanya kesenjangan riset yang mendorong perlunya pengembangan model *multimodal* yang mampu memahami hubungan antara teks dan gambar secara kontekstual dalam penelitian ini.

3.2.2 Studi Literatur

Tahap kedua dalam penelitian ini adalah studi literatur, yang mencakup kajian mendalam terhadap berbagai sumber ilmiah yang relevan dengan topik penelitian. Studi literatur ini bertujuan untuk memahami perkembangan metode

dalam analisis konten *multimodal*, khususnya dalam mendeteksi meme berbahaya yang memiliki makna implisit melalui kombinasi teks dan gambar. Pada tahap ini, ditinjau penelitian terkait pemanfaatan *Large Language Models* (LLM) sebagai *automatic annotator* untuk mengatasi keterbatasan anotasi manual, kemampuan model *multimodal* dalam memahami emosi serta konteks visual dan tekstual, serta berbagai pendekatan deteksi *harmful memes* yang umumnya memanfaatkan representasi visual dari model *Contrastive Language-Image Pre-training* (CLIP). Selain itu, kajian literatur juga menyoroti keterbatasan penelitian pada domain meme *self-harm* yang masih minim eksplorasi akibat keterbatasan *dataset*, sehingga diperlukan pendekatan alternatif seperti *pseudo-labeling* untuk membangun *dataset* secara efisien. Hasil studi literatur tersebut menjadi landasan teoritis dalam merumuskan kesenjangan riset serta menyusun rancangan model *multimodal* yang diusulkan dalam penelitian ini.

3.2.3 Pengumpulan Data

Pengumpulan data merupakan tahap penting dalam penelitian ini untuk memperoleh data yang relevan dan mendukung proses analisis. Pada tahap ini, data yang dikumpulkan berupa meme *multimodal* yang terdiri dari kombinasi elemen visual dan tekstual. Proses pengumpulan data dilakukan dari berbagai sumber secara sistematis agar data yang diperoleh memiliki kualitas yang baik dan dapat dipertanggungjawabkan. Berikut merupakan metode pengumpulan data yang digunakan dalam penelitian ini.

3.2.3.1 Pengumpulan Data dari Media Sosial

Pada penelitian ini, data meme dikumpulkan secara manual dari beberapa platform media sosial, yakni Reddit, Instagram, Facebook, dan X. Pengumpulan manual dipilih karena meme merupakan unit multimodal (teks dan gambar) yang maknanya sering muncul dari interaksi kedua modalitas, sehingga pengambilan data harus mempertahankan format asli (gambar + teks dalam satu konteks). Hal ini sejalan dengan temuan survei *harmful memes* yang menekankan bahwa konten berbahaya sering mengombinasikan beberapa modalitas dan tidak dapat dianalisis

secara unimodal saja [5].

Proses pengumpulan dilakukan dengan memasukkan kata kunci atau tagar terkait *self-harm* dan ideasi bunuh diri (contoh: #KMS, #IWannaCutMySelf, #depression, dan variasi lainnya) pada fitur pencarian masing-masing platform. Konten yang dianggap relevan kemudian disimpan sebagai tangkapan layar (*screenshot*) agar komposisi visual–tekstual tetap utuh. Strategi pencarian berbasis kata kunci dipandang relevan karena literatur menunjukkan adanya proliferasi konten *self-harm* di media sosial dan efek normalisasi yang bisa meningkat karena paparan berulang [45]. Pengumpulan manual ini memungkinkan peneliti untuk menyeleksi meme yang secara eksplisit atau implisit mengandung indikasi *self-harm*, sehingga dataset yang diperoleh lebih sesuai dengan tujuan penelitian.Dalam proses seleksi, konten dipilih berdasarkan kriteria sebagai berikut:

1. Memuat kombinasi teks dan gambar, atau teks yang ditempel pada gambar sehingga dapat dianalisis secara *multimodal*.
2. Konteks meme masih dapat dipahami dengan jelas.
3. Mengandung indikasi *self-harm*, baik secara eksplisit maupun implisit.

Proses pengumpulan data ini menghasilkan sebanyak 268 meme *self-harm*. Data tersebut kemudian diproses lebih lanjut pada tahap anotasi sebelum digunakan dalam pelatihan model multimodal.

3.2.3.2 Rekayasa Dataset Meme *Self-Harm*

Selain pengumpulan data melalui media sosial, penelitian ini melakukan rekayasa dataset untuk memperkaya variasi contoh *self-harm* dan meningkatkan keberagaman pola multimodal yang dapat dipelajari model. Langkah ini juga didorong oleh literatur *harmful memes* yang menyatakan bahwa beberapa kategori *harmful memes*, termasuk meme yang memuat *self-harm*, masih kurang diteliti karena keterbatasan dataset yang sesuai [5].

Rekayasa dataset dilakukan dengan membangun meme multimodal secara manual melalui penggabungan komponen tekstual dari dataset publik *Suicidal Ideation Detection Reddit Dataset* yang berisi postingan Reddit dengan label *suicidal* dan *non-suicidal*, serta komponen visual dari dataset publik bertipe *object*

detection yang memuat objek berbahaya pisau dan senjata api [46][47]. Gambar-gambar tersebut dipilih untuk merepresentasikan *visual cues* yang secara umum diasosiasikan dengan risiko kekerasan atau cedera tanpa harus menampilkan luka eksplisit.

Komponen teks dalam penelitian ini dipilih dari subset teks berlabel *suicidal* dengan tingkat kejelasan (*confidence*) yang tinggi terhadap indikasi keputusasaan, serta menghindari teks yang terlalu pendek atau ambigu. Penggunaan teks *suicidal* tidak dimaksudkan untuk menyamakan konsep *suicidal* dengan *self-harm*, melainkan karena keduanya memiliki keterkaitan dalam spektrum ekspresi *distress* psikologis dan sama-sama memancarkan sinyal negatif yang relevan untuk analisis risiko. Oleh karena itu, teks dengan indikasi *suicidal* digunakan sebagai pendekatan untuk merepresentasikan sinyal linguistik yang mendekati konteks *self-harm* dalam meme sintetis. Pemilihan ini bertujuan untuk membentuk meme sintetis yang secara semantik lebih konsisten dengan indikator risiko *self-harm*. Pertimbangan tersebut diperkuat oleh tinjauan sistematis yang menunjukkan bahwa paparan konten *self-harm*, bahkan tanpa representasi luka eksplisit, tetap dapat memicu berbagai dampak berbahaya seperti eskalasi *self-harm*, *social comparison*, dan terbentuknya *self-harm identity* [48]. Dengan demikian, kekuatan sinyal dalam konten, termasuk teks, menjadi faktor penting dalam membedakan konten berisiko tinggi dan rendah.

Rekayasa dataset ini menghasilkan 524 meme *self-harm* sintetis. Seluruh meme sintetis tersebut diperlakukan sebagai data penelitian yang harus melalui proses anotasi dan tidak otomatis dianggap benar, sehingga label akhir tetap ditentukan berdasarkan *annotation guideline* yang disusun berbasis literatur melalui *pseudo-labelling* oleh LLM yang akan dijelaskan dalam sub bab anotasi data.

3.2.3.3 Dataset Meme Umum sebagai Kandidat *Non-Self-Harm*

Selain data *self-harm* yang dikumpulkan secara langsung dari media sosial dan data hasil rekayasa dataset, penelitian ini juga menggunakan sebanyak 1.500 meme yang diambil dari dataset publik Kaggle berjudul *"6992 Labeled Meme Images Dataset"*. Dataset ini dikembangkan untuk keperluan analisis sentimen dan klasifikasi meme multimodal, sehingga memuat berbagai konteks humor umum,

ekspresi emosi sehari-hari, serta interaksi sosial yang lazim ditemukan di internet [49].

Dataset tersebut tidak secara eksplisit dirancang untuk tugas klasifikasi *self-harm*. Oleh karena itu, secara konseptual dataset ini dapat mengandung konten yang bersifat netral maupun konten yang berpotensi ambigu. Dalam penelitian ini, dataset tersebut tidak diasumsikan sebagai *non-self-harm*, melainkan diperlakukan sebagai kumpulan data kandidat yang diharapkan mayoritas merepresentasikan konten *non-self-harm*. Pemilihan dataset meme umum ini bertujuan untuk menyediakan *baseline* konten netral serta memperkaya distribusi data selama proses *pseudo-labeling*. Label akhir dari setiap meme dalam dataset ini ditentukan pada tahap anotasi data menggunakan *annotation guideline* berbasis literatur dan pendekatan *ensemble pseudo-labeling*. Dengan demikian, jumlah data yang pada akhirnya dilabeli sebagai *non-self-harm* maupun *self-harm* baru dapat dipastikan setelah seluruh proses anotasi selesai.

Pendekatan ini sejalan dengan praktik *weak supervision*, dimana data mentah yang belum memiliki label spesifik dimasukkan ke dalam *pipeline* anotasi dan pelabelan otomatis, kemudian ditentukan kelas akhirnya melalui agregasi beberapa sumber pelabelan, bukan berdasarkan asumsi awal [50].

3.2.3.4 Ringkasan Komposisi Dataset Awal

Berikut komposisi *dataset* awal yang digunakan dalam penelitian ini. *Dataset* diperoleh dari tiga sumber utama, yaitu data *self-harm* dari media sosial, data hasil rekayasa *dataset*, serta meme umum dari *dataset* publik sebagai pembanding. Rincian jumlah masing-masing data disajikan pada Tabel 3.1.

Tabel 3.1 Komposisi Dataset Awal Penelitian

No	Jenis Data	Sumber Data	Jumlah	Keterangan
1	*Self-harm* (Media Sosial)	Primer	268	Data dikumpulkan langsung dari platform media sosial
2	*Self-harm* (Rekayasa *Dataset*)	Sekunder	524	Data sintetis hasil penggabungan teks dan gambar
3	Meme Umum (*Dataset* Publik)	Sekunder	1.500	Kandidat *non-self-harm* yang akan melalui proses anotasi
	Total		**2.292**	Dataset awal sebelum proses anotasi

3.2.4 *Pre-processing* Awal

Pre-processing awal dilakukan sebelum tahap anotasi data dengan tujuan untuk menyiapkan data agar lebih efisien dalam proses pemrosesan *multimodal*. Tahap ini berfokus pada penyeragaman ukuran data serta pengurangan kompleksitas komputasi tanpa menghilangkan informasi penting yang terkandung dalam meme. Pada tahap ini, seluruh gambar diubah ukurannya menjadi 224×224 piksel untuk mengurangi kebutuhan komputasi dan biaya pemrosesan, dengan tetap menjaga keterbacaan teks yang terdapat pada meme.

Pemilihan ukuran 224×224 piksel juga disesuaikan dengan kebutuhan *input* model *vision encoder* CLIP yang digunakan dalam penelitian ini, sehingga data yang dihasilkan kompatibel dengan arsitektur model tanpa memerlukan penyesuaian tambahan pada tahap pelatihan. Selain itu, ukuran ini mempertimbangkan keseimbangan antara efisiensi pemrosesan dan kualitas informasi visual, sehingga baik elemen gambar maupun teks tetap dapat dianalisis dengan baik oleh model *vision-language*. Dengan demikian, proses *pre-processing* awal ini memastikan bahwa data yang digunakan pada tahap anotasi memiliki format yang seragam, lebih ringan untuk diproses, serta tetap merepresentasikan konten *multimodal* secara optimal.

3.2.5 Anotasi Data

Tahap anotasi data dalam penelitian ini menggunakan pendekatan *ensemble pseudo-labeling* dengan memanfaatkan dua model *vision-language*, yaitu GPT-4o mini dan Qwen-VL-Flash, untuk menghasilkan label biner *self-harm* dan *non self-*

harm pada meme *multimodal*. Pendekatan ini memanfaatkan kemampuan analisis *multimodal* dari kedua model dalam memahami hubungan antara elemen visual dan tekstual, sehingga diharapkan dapat meningkatkan akurasi pelabelan.

Proses anotasi menghasilkan beberapa komponen keluaran, yaitu *filename*, teks terlihat, label, serta relasi antara gambar dan teks. Komponen teks terlihat berfungsi sebagai representasi teks yang diekstraksi langsung dari gambar dan digunakan sebagai pengganti proses *optical character recognition* (OCR) pada tahap pelatihan model. Sementara itu, komponen relasi gambar dan teks digunakan untuk mendukung proses peninjauan ulang secara manual, terutama pada kasus yang bersifat ambigu.

Kedua model, yaitu GPT-4o mini dan Qwen-VL-Flash, menghasilkan keluaran dengan format yang seragam untuk setiap data. Apabila kedua model menghasilkan label yang konsisten, maka label tersebut digunakan sebagai label akhir. Namun, apabila terjadi perbedaan (*disagreement*), dilakukan proses peninjauan ulang secara manual oleh peneliti dengan mengacu pada *annotation guideline*. Pada tahap ini, dilakukan pula verifikasi terhadap teks terlihat untuk memastikan kesesuaiannya dengan teks asli pada gambar.

Berdasarkan hasil evaluasi selama proses anotasi, keluaran teks terlihat dari GPT-4o mini menunjukkan tingkat kesesuaian yang lebih tinggi dibandingkan Qwen-VL-Flash. Oleh karena itu, pada *dataset* final, komponen teks yang digunakan dalam pelatihan model diambil dari hasil ekstraksi GPT-4o mini. Penjelasan lebih lanjut mengenai *prompting* dan *annotation guideline* disajikan pada subbab berikutnya. Distribusi label akhir yang dihasilkan dari proses anotasi ini disajikan pada Bab IV.

3.2.5.1 *Framework Prompting* (*RapGuard*)

Kerangka *RapGuard* digunakan untuk menangani kompleksitas analisis meme yang memadukan teks dan gambar, sebagai dasar dalam perancangan *prompting* yang digunakan ke *Large Language Model* (LLM). Kerangka ini digunakan karena metode *prompting* sederhana atau statis pada umumnya hanya menganalisis teks atau gambar secara terpisah, sehingga berpotensi mengabaikan risiko yang baru

muncul ketika kedua modalitas tersebut digabungkan. *RapGuard* secara khusus dirancang untuk mendorong model melakukan analisis terstruktur terhadap tiga aspek utama, yaitu konten visual, konten tekstual, serta hubungan antara teks dan gambar. Selain itu, kerangka ini juga menyertakan tahap *self-checking*, dimana model diminta untuk meninjau kembali keputusan awalnya secara kritis sebelum memberikan label akhir. Pendekatan ini bertujuan untuk meningkatkan keandalan pelabelan, terutama pada kasus meme yang bersifat ambigu, menggunakan humor gelap, atau menyembunyikan makna berbahaya secara implisit [51]. Dengan demikian, penggunaan *RapGuard* memungkinkan proses anotasi dilakukan secara lebih sistematis dan konsisten, tanpa penilaian tunggal terhadap satu modalitas.

3.2.5.2 *Annotation Guideline* Berbasis Literatur

Annotation guideline dalam penelitian ini disusun berdasarkan studi literatur dan dirancang untuk memastikan proses anotasi dilakukan secara sistematis dan konsisten. *Guideline* ini terdiri dari tiga tahap analisis utama, yaitu analisis visual, analisis tekstual, dan analisis relasional yang berfokus pada hubungan antara elemen gambar dan teks dalam meme.

Selain itu, indikator *self-harm* dalam penelitian ini dibagi menjadi dua kategori utama, yaitu indikator naratif/tekstual dan indikator visual/simbolik. Indikator tersebut mencakup berbagai aspek, seperti deskripsi metode, ideasi kematian, romantisasi *self-harm*, keberadaan objek berbahaya, representasi luka fisik, serta kontras ironis antara visual dan teks yang memperkuat makna implisit. Aturan pelabelan dalam *guideline* ini menyatakan bahwa suatu meme diklasifikasikan sebagai *self-harm* apabila memenuhi minimal satu indikator yang relevan, khususnya indikator relasional yang menunjukkan keterkaitan antara teks dan gambar. Selain itu, proses anotasi juga dilengkapi dengan tahap *self-checking* untuk mengurangi subjektivitas dalam interpretasi meme yang bersifat ambigu. Rincian lengkap mengenai *annotation guideline* yang digunakan dalam penelitian ini disajikan pada Lampiran.

3.2.5.3 *Ensemble Pseudo-Labeling*

Proses pelabelan dilakukan menggunakan pendekatan *ensemble pseudo-labeling* dengan dua model *vision-language*, yaitu GPT-4o dan Qwen-VL-Flash. Seluruh data dianotasi secara independen oleh kedua model menggunakan *prompt* dan *annotation guideline* yang sama. Apabila kedua model menghasilkan label yang sama, label tersebut diterima sebagai label akhir. Namun, apabila terdapat perbedaan label antara kedua model, data tersebut ditinjau ulang secara manual oleh peneliti berdasarkan *annotation guideline* untuk menentukan label akhir.

3.2.5.4 Penentuan Label

Perbedaan hasil pelabelan antara dua model dapat terjadi pada beberapa sampel meme. Dalam kondisi tersebut, dilakukan peninjauan ulang secara manual oleh peneliti untuk menetapkan label akhir. Proses ini bertujuan untuk memastikan bahwa keputusan pelabelan tidak hanya bergantung pada satu hasil prediksi model, melainkan mempertimbangkan analisis yang lebih komprehensif. Penetapan label akhir mengacu pada indikator yang telah ditetapkan dalam *annotation guideline* berbasis studi literatur, serta mempertimbangkan keluaran tambahan berupa relasi antara gambar dan teks yang dihasilkan oleh masing-masing model. Selain itu, hasil ekstraksi teks terlihat juga diverifikasi untuk memastikan kesesuaiannya dengan teks asli pada gambar, sehingga analisis yang dilakukan benar-benar merepresentasikan konten aktual pada meme.

Meme diklasifikasikan sebagai *self-harm* apabila memenuhi setidaknya satu indikator yang berkaitan dengan *self-harm*, khususnya indikator relasional yang menunjukkan keterkaitan antara teks dan gambar. Sebaliknya, meme diklasifikasikan sebagai *non self-harm* apabila tidak ditemukan indikator yang relevan dan konteks yang ditampilkan hanya berupa humor umum atau ekspresi sehari-hari. Pendekatan ini digunakan untuk meminimalkan kemungkinan konten berisiko tidak teridentifikasi, sekaligus tetap mempertimbangkan karakteristik meme yang sering menyampaikan makna secara implisit melalui humor, ironi, atau metafora.

3.2.6 *Pre-processing Data*

Setelah anotasi selesai, seluruh data memasuki tahap *pre-processing* untuk memastikan kualitas input yang optimal. Pada modalitas gambar, *pre-processing* meliputi penyesuaian resolusi, normalisasi piksel, dan konversi format untuk menyesuaikan standar masukan CLIP. Pada modalitas teks, *pre-processing* mencakup pembersihan karakter khusus, normalisasi huruf, tokenisasi, serta penghilangan duplikasi. Tahap ini penting agar model dapat mempelajari pola secara konsisten.

3.2.6.1 *Flip*

Flipping horizontal diterapkan pada gambar untuk meningkatkan kemampuan model dalam mengenali objek dari berbagai orientasi. Pada tahap ini, gambar dibalik secara acak secara horizontal dengan probabilitas 50%. Teknik ini memungkinkan model untuk tidak bergantung pada orientasi tertentu, sehingga model tetap dapat mendeteksi objek meskipun posisinya berubah, seperti ketika objek menghadap ke kiri atau kanan. Contoh dari augmentasi ini dapat dilihat pada Gambar 3.2, yang menunjukkan perbandingan antara gambar asli dan hasil augmentasi.

(a) Gambar asli

(b) Gambar setelah *flip horizontal*

Gambar 3.2 Perbandingan gambar asli dan hasil augmentasi *flip horizontal*

3.2.6.2 *Rotation*

Selain *flipping horizontal*, *rotasi acak* juga diterapkan pada gambar. Pada tahap ini, gambar diputar secara acak dengan rotasi sebesar 15 derajat. Dengan menambahkan rotasi acak, model dapat meningkatkan ketahanannya terhadap

perubahan orientasi gambar. Contoh dari augmentasi ini dapat dilihat pada Gambar 3.3, yang menunjukkan perbandingan antara gambar asli dan hasil augmentasi rotasi.

(a) Gambar asli

(b) Gambar setelah *rotasi*

Gambar 3.3 Perbandingan gambar asli dan hasil augmentasi *rotasi acak*

3.2.6.3 *Color Jitter*

*Color jitter*juga diterapkan pada gambar untuk meningkatkan ketahanan model terhadap variasi pencahayaan dan warna. Pada tahap ini, kecerahan kontras, dan saturasi diubah secara acak dengan nilai 0.2 sedangkan rona diubah secara acak 0.1. Teknik ini bertujuan untuk memperkaya variasi gambar dalam dataset, sehingga model dapat belajar mengenali objek dengan lebih baik meskipun dalam kondisi pencahayaan yang berbeda atau variasi warna yang bervariasi. Contoh dari augmentasi ini dapat dilihat pada Gambar 3.4, yang menunjukkan perbandingan antara gambar asli dan hasil augmentasi *color jitter*.

(a) Gambar asli

(b) Gambar setelah *color jitter*

Gambar 3.4 Perbandingan gambar asli dan hasil augmentasi *color jitter*

3.2.6.4 *Lowercasing*

Pada modalitas teks, *lowercasing* dilakukan menggunakan ELECTRA *tokenizer* yang mengubah semua huruf kapital menjadi huruf kecil. Proses ini bertujuan untuk menyederhanakan representasi teks sehingga model tidak perlu membedakan antara huruf besar dan kecil, yang dapat mengurangi kompleksitas pemrosesan.

3.2.7 Pengembangan Model Arsitektur Multimodal

Berikut adalah tahapan dalam pengembangan model arsitektur multimodal dengan menggunakan penggabungan fitur dalam tingkat menengah *intermediate fusion*

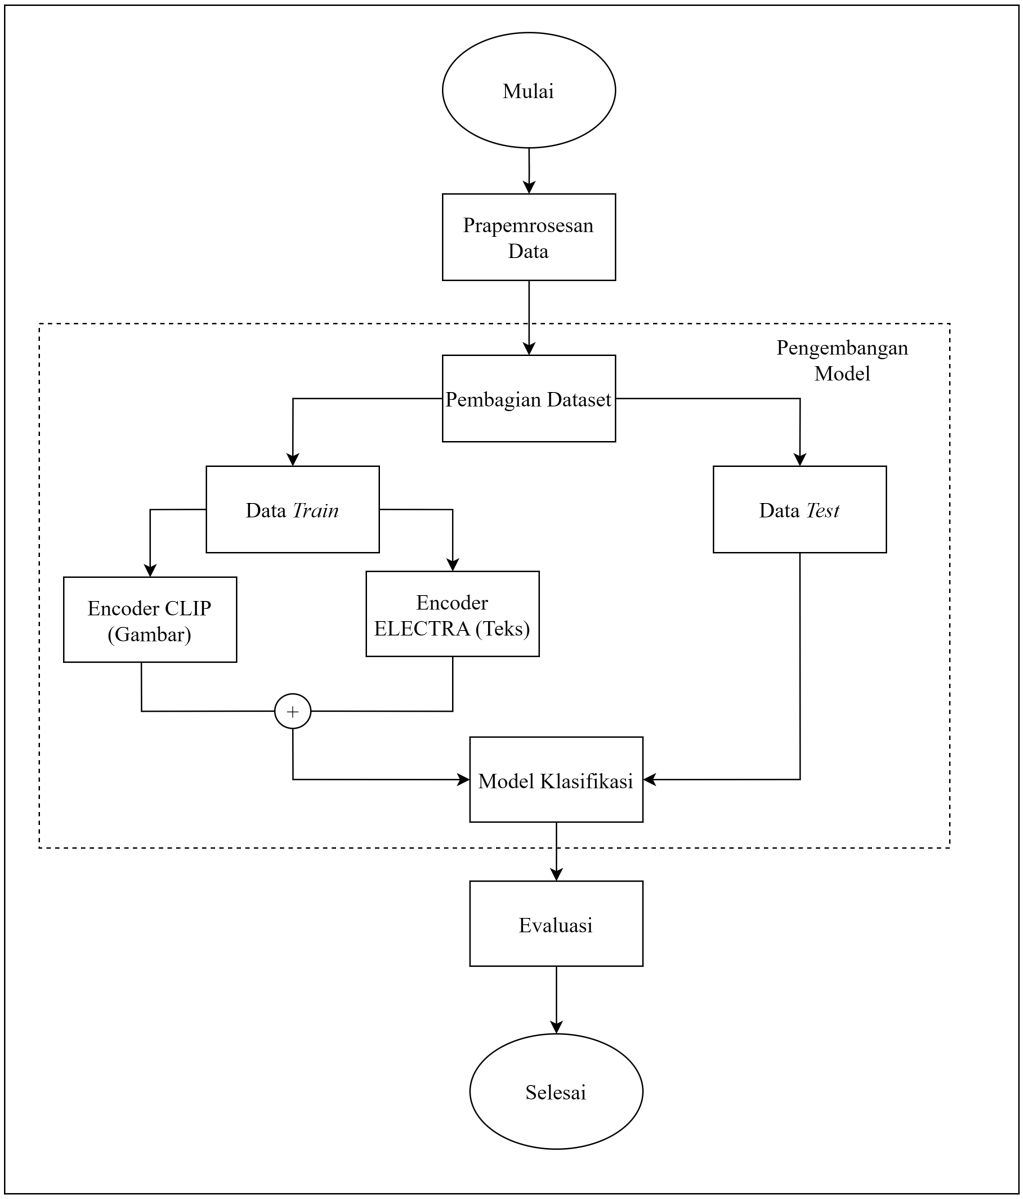

Gambar 3.5 Alur Pengembangan Model

3.2.7.1 Pembagian Data

Data yang telah melewati tahap *pre-processing* selanjutnya dibagi menjadi dua *subset* utama dengan rasio 80:20 secara random. Sebanyak 80% dari total data sebagai data latih (*training set*) untuk proses pembelajaran model, sedangkan 20% sisanya digunakan sebagai data uji (*testing set*). Pembagian ini bertujuan untuk memastikan bahwa model memiliki porsi data yang cukup besar untuk mempelajari pola fitur multimodal secara optimal, sekaligus menyisakan data yang representatif

untuk evaluasi kinerja yang objektif tanpa terjadi kebocoran data (*data leakage*).par

3.2.7.2 Pelatihan model

Tahap pelatihan model dilakukan dengan arsitektur *dual-encoder* yang menggabungkan dua modalitas input. Untuk ekstraksi fitur visual, penelitian ini menggunakan model CLIP (*Contrastive Language-Image Pre-training*) varian CLIP ViT *base patch-size* 32 dengan parameter 151 juta. Pemilihan CLIP didasarkan pada efektivitasnya yang telah terbukti dalam studi literatur terdahulu, seperti pada framework MOMENTA [21] dan Hate-CLIPper [22], dimana representasi visual CLIP terbukti krusial dalam menangkap hubungan semantik lintas-modalitas dan mengenali konten implisit tanpa memerlukan arsitektur yang terlalu kompleks. Pada penelitian ini, model CLIP digunakan murni sebagai ekstraktor fitur *(feature extractor)* tanpa dilakukan proses *fine-tuning,* sehingga seluruh parameter visual encoder tetap dibekukan *(frozen)* selama pelatihan.

Model *ELECTRA* varian *Suicidal-Electra*, adalah model yang telah dilatih untuk mendeteksi kecenderungan bunuh diri dalam teks. Model ini berbasis pada arsitektur transformer, yang unggul dalam memahami konteks kata-kata dalam suatu urutan kalimat. Model ini dilatih menggunakan dataset besar yang berisi postingan *suicidal* (bunuh diri) dan *non-suicidal* (tidak bunuh diri), yang memungkinkan model untuk mengenali pola bahasa, metafora, dan ekspresi yang terkait dengan pemikiran bunuh diri. Pada penelitian ini, model digunakan murni sebagai *feature extractor* tanpa dilakukan proses *fine-tuning*, sehingga seluruh parameter visual encoder tetap dibekukan (frozen) selama pelatihan. *Suicidal-Electra* memiliki *parameter* 110 juta [52].

3.2.7.3 *Fusion* model

Dalam penelitian ini, digunakan dua arsitektur *model fusion* yang berbeda untuk menggabungkan informasi dari teks dan gambar. Kedua arsitektur ini dirancang untuk mendeteksi kecenderungan bunuh diri melalui analisis multimodal, yaitu teks dan gambar. Arsitektur yang dirancang sebagai berikut:

Gambar 3.6 menunjukkan rancangan arsitektur fusion model varian pertama.

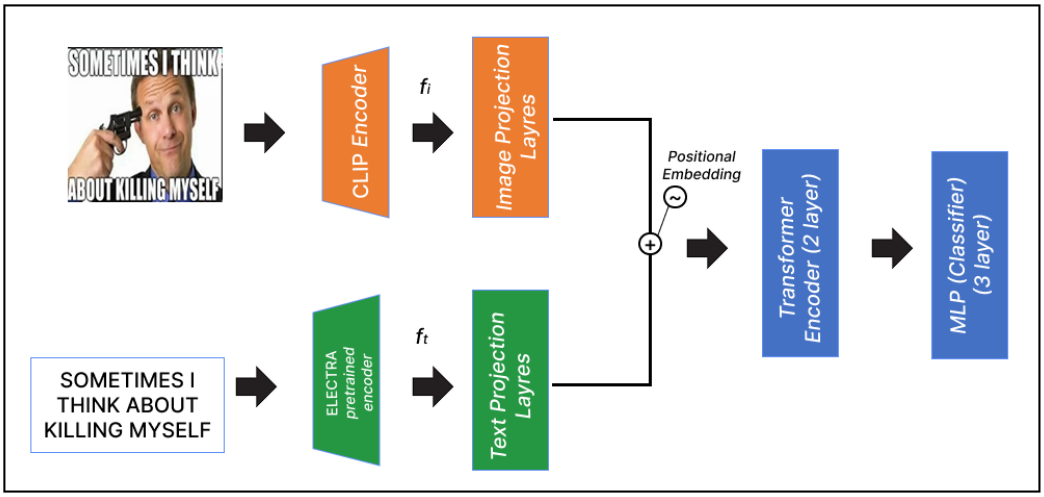

Gambar 3.6 Rancangan Fusion Model Varian 1

Model ini menggunakan Transformer Encoder untuk interaksi antara modalitas teks dan gambar. Proses pertama dimulai dengan pemrosesan CLIP *encoder* untuk mengekstrak fitur dari gambar, yang kemudian diproyeksikan ke dalam *Image Projection Layers*. Di sisi lain, teks diproses menggunakan *ELECTRA Pretrained Encoder* yang juga diproyeksikan ke dalam *Text Projection Layers*. Fitur dari teks dan gambar kemudian digabungkan dengan menggunakan *Positional Embedding*. Setelah itu, gabungan fitur dari kedua modalitas ini diproses melalui Transformer Encoder yang memungkinkan model untuk memahami hubungan dan konteks antara teks dan gambar. Hasil dari proses ini selanjutnya diteruskan ke *Multi Layer Perceptron* (MLP) untuk klasifikasi.

Gambar 3.7 menunjukkan rancangan arsitektur fusion model varian kedua. Berbeda dengan varian pertama, model ini tidak menggunakan Transformer Encoder untuk interaksi antar-modalitas. Melainkan langsung menggabungkan fitur teks dan gambar untuk masuk ke MLP. Model ini lebih sederhana dibandingkan varian pertama.

3.2.8 Evaluasi Model

Evaluasi kinerja model dilakukan menggunakan metrik standar yang diturunkan dari *Confusion Matrix*, yang meliputi *accuracy*, *precision*, *recall*, dan *F1-Score*. Mengingat urgensi dan sensitivitas identifikasi konten meme *self-harm*, evaluasi

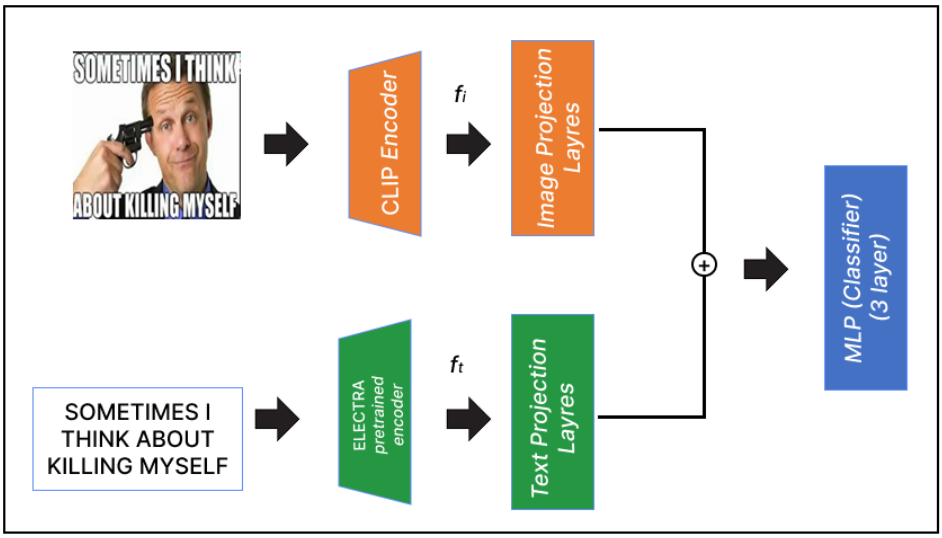

Gambar 3.7 Rancangan Fusion Model Varian 2

tidak hanya berfokus pada akurasi global, tetapi lebih evaluasi pada *recall* untuk memastikan sistem mampu meminimalkan risiko lolosnya konten berbahaya (*false negative*), serta *precision* untuk menjaga validitas prediksi positif. Sebagai metrik penentu, *F1-Score* digunakan untuk menyeimbangkan antara *precision* dan *recall*, sehingga memberikan gambaran objektif mengenai keandalan model dalam mengklasifikasikan fitur multimodal secara efektif pada dataset yang kompleks.

3.2.9 Analisis Hasil dan Pembahasan

Tahap akhir penelitian ini adalah analisis hasil dan pembahasan. Pada tahap ini, hasil evaluasi model dianalisis untuk melihat seberapa baik model dalam mengenali meme *self-harm*. Analisis meliputi penjelasan metrik evaluasi, kesalahan yang terjadi, serta kelebihan dan kekurangan model. Pembahasan juga mencakup manfaat hasil penelitian dan saran untuk pengembangan selanjutnya.

3.3 Alat dan Bahan Tugas Akhir

Berisi alat-alat dan bahan-bahan yang digunakan dalam penelitian.

3.3.1 *Software dan Library*

Software dan library yang digunakan untuk mendukung pelaksanaan penelitian ini dengan rincian sebagai berikut:

1. *Code Editor* Visual Studio Code untuk penulisan kode program.
2. *Library Deep Learning* `PyTorch` digunakan untuk implementasi dan pelatihan model.
3. Platform *Cloud Computing* `Runpod` untuk eksekusi kode Python dan pelatihan model memanfaatkan akselerasi GPU berbasis *cloud*, dengan perangkat keras GPU `NVIDIA RTX 4090`.
4. GitHub sebagai media penyimpanan repositori (*repository*) dan manajemen kode.
5. Platform desain `Canva` yang digunakan dalam proses pembuatan dataset meme secara manual (*constructed dataset*).

3.3.2 Dataset

Dataset yang digunakan dalam penelitian ini terdiri dari tiga sumber dataset. Pertama, dataset meme yang dikumpulkan secara manual dari berbagai platform internet, yang mencakup kombinasi gambar dan teks. Kedua, dataset yang dibuat sendiri *(constructed dataset)* sebanyak 500 meme. Ketiga, dataset publik dari Kaggle berupa *"6992 Meme Images Dataset with Labels"* yang diintegrasikan untuk memperkaya dan meningkatkan keragaman dataset penelitian [49].

3.4 Ilustrasi Perhitungan Metode

Pada bagian ini, akan dijelaskan ilustrasi perhitungan metode yang digunakan dalam penelitian ini.

3.4.1 Ilustrasi Perhitungan *contrastive loss* (InfoNCE)

Pada bagian ini, akan dihitung *loss* menggunakan Rumus 2.2. InfoNCE digunakan untuk menghitung kesamaan antara representasi gambar dan teks. Misalkan terdapat dua pasangan gambar-teks sebagai berikut:

- Pasangan 1: L_1 dengan T_1
- Pasangan 2: L_2 dengan T_2

Nilai kesamaan kosinus (*cosine similarity*) untuk setiap pasangan adalah:

$$\cos(f_L(L_1), f_T(T_1)) = 0.85$$
$$\cos(f_L(L_1), f_T(T_2)) = 0.45$$
$$\cos(f_L(L_2), f_T(T_1)) = 0.40$$
$$\cos(f_L(L_2), f_T(T_2)) = 0.75$$

Dengan parameter suhu $\tau = 0.07$, nilai *loss* untuk pasangan pertama L_1, T_1 dapat dihitung menggunakan rumus InfoNCE berikut:

$$\mathcal{L}_1 = -\frac{1}{2}\left(\log\left(\frac{e^{\cos(f_L(L_1), f_T(T_1))/\tau}}{\sum_{i=1}^{2} e^{\cos(f_L(L_1), f_T(T_i))/\tau}}\right) + \log\left(\frac{e^{\cos(f_T(T_1), f_L(L_1))/\tau}}{\sum_{i=1}^{2} e^{\cos(f_T(T_1), f_L(L_i))/\tau}}\right)\right)$$

Substitusi nilai *cosine similarity*:

$$\cos(f_L(L_1), f_T(T_1)) = 0.85, \quad \cos(f_L(L_1), f_T(T_2)) = 0.45$$
$$\cos(f_T(T_1), f_L(L_1)) = 0.85, \quad \cos(f_T(T_1), f_L(L_2)) = 0.40$$

Term pertama:

$$\frac{\exp(0.85/0.07)}{\exp(0.85/0.07) + \exp(0.45/0.07)} \approx \frac{1.751 \times 10^5}{1.751 \times 10^5 + 624.8}$$
$$\approx 0.9996$$

Term kedua:

$$\frac{\exp(0.85/0.07)}{\exp(0.85/0.07) + \exp(0.40/0.07)} \approx \frac{1.751 \times 10^5}{1.751 \times 10^5 + 302.5}$$
$$\approx 0.9998$$

Substitusi ke dalam rumus:

$$\mathcal{L}_1 = -\frac{1}{2}\Big[\log(0.9996) + \log(0.9998)\Big]$$

Logaritma:

$$\log(0.9996) \approx -0.0004, \quad \log(0.9998) \approx -0.0002$$

Hasil akhir:

$$\mathcal{L}_1 = -\frac{1}{2}\left[-0.0004 + (-0.0002)\right] = 0.0003$$

3.4.2 Ilustrasi Perhitungan *Token Detection Loss* pada ELECTRA

Pada bagian ini, akan dihitung *loss* menggunakan Rumus 2.3. Misalkan terdapat sebuah kalimat yang terdiri dari 3 token, yaitu:

$$\text{Kalimat: } \{\text{"}Saya\text{"}, \text{"}pergi\text{"}, \text{"}ke\text{"}\}$$

Kemudian, hasil generator model untuk token-token tersebut adalah:

$$\text{Hasil Generator: } \{\text{"}Saya\text{"}, \text{"}berlari\text{"}, \text{"}ke\text{"}\}$$

Dari kalimat di atas, diketahui bahwa:
- Token "Saya" adalah token asli ($y_1 = 1$).
- Token "pergi" digantikan dengan token "berlari" (hasil generator), sehingga $y_2 = 0$.
- Token "ke" adalah token asli ($y_3 = 1$).

Kemudian, probabilitas $D(x_i)$ yang diberikan oleh diskriminator untuk setiap token adalah sebagai berikut:

$$D(\text{"}Saya\text{"}) = 0.95, \quad D(\text{"}berlari\text{"}) = 0.05, \quad D(\text{"}ke\text{"}) = 0.90$$

Sekarang, dapat dihitung $\mathcal{L}_{RTD}$ untuk kalimat ini dengan menggunakan rumus yang telah diberikan.

$$\begin{aligned}
\mathcal{L}_{RTD} = &- [y_1 \log D(\text{"}Saya\text{"}) + (1 - y_1) \log(1 - D(\text{"}Saya\text{"})) \\
&+ y_2 \log D(\text{"}berlari\text{"}) + (1 - y_2) \log(1 - D(\text{"}berlari\text{"})) \\
&+ y_3 \log D(\text{"}ke\text{"}) + (1 - y_3) \log(1 - D(\text{"}ke\text{"}))] \\
= &- [1 \cdot \log(0.95) + 0 \cdot \log(1 - 0.95) \\
&+ 0 \cdot \log(0.05) + 1 \cdot \log(1 - 0.05) \\
&+ 1 \cdot \log(0.90) + 0 \cdot \log(1 - 0.90)]
\end{aligned}$$

Setelah mengganti nilai logaritma:

$$\begin{aligned}
\mathcal{L}_{RTD} &= - [\log(0.95) + \log(0.95) + \log(0.90)] \\
&= - [-0.0223 + -0.0223 + -0.1054] \\
&= 0.15
\end{aligned}$$

Dengan demikian, nilai dari $\mathcal{L}_{RTD}$ untuk kalimat ini adalah 0.15.

3.4.3 Ilustrasi Perhitungan Metrik Evaluasi

Berikut ilustrasi perhitungan metrik evaluasi pada Rumus 2.7, Rumus 2.8, Rumus 2.9, dan **??**.

Dimana:

TP *(True Positive)*: Jumlah prediksi positif yang benar.

TN *(True Negative)*: Jumlah prediksi negatif yang benar.

FP *(False Positive)*: Jumlah prediksi positif yang salah.

FN *(False Negative)*: Jumlah prediksi negatif yang salah.

Misalkan terdapat hasil pengujian model dengan jumlah sebagai berikut:

$TP = 50$

$TN = 40$

$FP = 10$

$FN = 5$

Dengan nilai-nilai tersebut, metrik evaluasi dapat dihitung sebagai berikut:

$$\begin{aligned} Accuracy &= \frac{TP + TN}{TP + TN + FP + FN} \\ &= \frac{50 + 40}{50 + 40 + 10 + 5} \\ &= \frac{90}{105} \\ &= 0.8571 \end{aligned}$$

Jadi, *Accuracy* = 0.8571 atau 85.71%.

$$\begin{aligned} Precision &= \frac{TP}{TP + FP} \\ &= \frac{50}{50 + 10} \\ &= \frac{50}{60} \\ &= 0.8333 \end{aligned}$$

Jadi, *Precision* = 0.8333 atau 83.33%.

$$
\begin{aligned}
Recall &= \frac{TP}{TP + FN} \\
&= \frac{50}{50 + 5} \\
&= \frac{50}{55} \\
&= 0.9091
\end{aligned}
$$

Jadi, *Recall* = 0.9091 atau 90.91%.

$$
\begin{aligned}
F1 &= 2 \times \frac{Precision \times Recall}{Precision + Recall} \\
&= 2 \times \frac{0.8333 \times 0.9091}{0.8333 + 0.9091} \\
&= 2 \times \frac{0.7562}{1.7424} \\
&= 2 \times 0.4330 \\
&= 0.8660
\end{aligned}
$$

Jadi, *F1 Score* = 0.8660 atau 86.60%.

Dari perhitungan di atas, dapat disimpulkan bahwa model memiliki: - *Accuracy* = 85.71% - *Precision* = 83.33% - *Recall* = 90.91% - *F1 Score* = 86.60%

Metrik-metrik ini memberikan gambaran yang lebih lengkap tentang performa model dalam mengklasifikasikan data dengan benar, baik dalam hal ketepatan (*precision*) maupun dalam mengidentifikasi seluruh data positif yang relevan (*recall*).

BAB IV
HASIL DAN PEMBAHASAN

4.1 Pengumpulan Data

Pada tahap ini dilakukan proses pengumpulan dataset yang akan digunakan. Dataset disusun dari tiga sumber utama, yaitu rekayasa dataset *self-harm*, pengumpulan meme dari media sosial, serta pemilihan meme umum dari dataset publik sebagai kandidat *non-self-harm*. Seluruh data yang dikumpulkan berbentuk multimodal, yaitu terdiri dari kombinasi gambar dan teks dalam satu meme. Tahap pengumpulan ini bertujuan untuk membangun dataset yang beragam dan representatif sebelum memasuki proses anotasi dan pemodelan.

4.1.1 Dataset Primer

Dataset primer terdiri dari dua komponen utama, yaitu dataset rekayasa multimodal dan dataset yang dikumpulkan langsung dari media sosial. Kedua komponen ini dirancang khusus untuk membangun representasi meme yang mengandung indikasi *self-harm*.

4.1.1.1 Dataset Rekayasa Multimodal

Rekayasa dataset dilakukan untuk menghasilkan meme dengan tema *self-harm* secara multimodal karena belum tersedia dataset publik yang secara khusus menyediakan kombinasi gambar dan teks untuk kategori meme *self-harm*. Komponen visual diperoleh dari dataset *Weapon and Knife Detection 137K Images* yang tersedia secara publik, kemudian dipilih secara manual berdasarkan kualitas gambar dan kejelasan objek. Sementara itu, komponen teks diambil dari *Suicidal Ideation Detection Reddit Dataset* yang bersumber dari unggahan komunitas Reddit, dengan menggunakan atribut *Title* yang memiliki nilai *confidence* tertinggi.

Teks yang terlalu panjang diringkas menjadi satu kalimat utama dengan tetap mempertahankan konteks makna, serta melalui tahap pembersihan karakter dan

penghapusan duplikasi data. Selanjutnya, gambar dan teks digabungkan secara acak untuk membentuk meme multimodal menghasilkan variasi konteks visual dan tekstual yang beragam sehingga model mampu melakukan generalisasi dengan lebih baik. Dari proses rekayasa ini diperoleh sebanyak 524 meme multimodal yang digunakan dalam penelitian. Rincian lebih lengkap dapat dilihat pada Tabel 4.1.

Tabel 4.1 Sumber Data Rekayasa Dataset

Komponen	**Sumber**	**Tersedia**	**Digunakan**
Gambar	*Weapon & Knife Detection (Kaggle)*	137.000+	524
Teks	*Suicidal Ideation Reddit Dataset*	15.477	524
		Total Meme Rekayasa	**524**

4.1.1.2 Dataset Media Sosial

Selain melakukan rekayasa dataset, penelitian ini juga melakukan pengumpulan meme secara langsung dari berbagai platform media sosial, yaitu Reddit, Instagram, Twitter/X, Facebook, dan Threads. Proses pencarian dilakukan dengan menggunakan kata kunci dan tagar yang berkaitan dengan *self-harm* serta *suicidal ideation*, seperti *#selfharm*, *#depression*, *#iwannakillmyself*, *#kms*, dan variasi serupa. Pemilihan kata kunci tersebut bertujuan untuk menjaring konten yang berpotensi mengandung indikasi *self-harm*, baik yang disampaikan secara langsung maupun melalui bentuk ekspresi tidak langsung seperti ironi atau humor gelap.

Setiap meme yang ditemukan kemudian melalui proses seleksi manual berdasarkan beberapa kriteria, yaitu meme harus terdiri dari kombinasi gambar dan teks, teks dapat dibaca dengan jelas, serta mengandung indikasi *self-harm* secara eksplisit maupun implisit. Melalui proses ini, diperoleh sebanyak 268 meme yang digunakan sebagai bagian dari dataset penelitian.

4.1.2 Dataset Sekunder

Dataset sekunder yang digunakan dalam penelitian ini merupakan dataset publik berjudul *"6992 Meme Images Dataset with Labels"* yang tersedia di platform Kaggle. Dataset tersebut berisi ribuan meme dari berbagai topik umum yang tidak secara khusus berkaitan dengan *self-harm*. Dalam penelitian ini, dataset tersebut

dimanfaatkan sebagai sumber kandidat untuk kelas *non-self-harm* guna memberikan pembanding terhadap meme yang mengandung indikasi *self-harm*.

Dari total 6.992 gambar yang tersedia, dipilih sebanyak 1.400 gambar melalui proses pengambilan sampel secara acak. Pemilihan jumlah tersebut dilakukan untuk menjaga keseimbangan proporsi data agar kelas *non-self-harm* tidak mendominasi keseluruhan dataset, sehingga dapat mengurangi potensi bias pada proses pelatihan model. Label asli yang tersedia pada dataset tersebut tidak digunakan secara langsung karena penelitian ini akan melakukan proses anotasi ulang pada seluruh data. Sebelum digunakan, seluruh gambar yang terpilih diperiksa secara manual untuk memastikan bahwa meme terdiri dari kombinasi gambar dan teks yang masih dapat terbaca dengan jelas, sehingga tetap memenuhi karakteristik data multimodal yang digunakan dalam penelitian ini.

4.1.3 Komposisi Dataset

Setelah seluruh tahapan pengumpulan data selesai dilakukan, diperoleh total sebanyak 2.192 meme multimodal yang berasal dari tiga sumber utama, yaitu hasil rekayasa dataset *self-harm*, pengumpulan langsung dari media sosial, serta dataset meme umum dari Kaggle sebagai kandidat *non-self-harm*. Ketiga sumber tersebut digabungkan untuk membentuk kumpulan data awal yang akan digunakan pada tahap anotasi dan pengolahan selanjutnya.

Seluruh data yang telah dikumpulkan kemudian melalui proses penyeragaman format, termasuk penggantian nama file menjadi sistem penomoran numerik berurutan untuk memudahkan pengelolaan dan pelacakan data selama proses penelitian. Tahap ini dilakukan untuk memastikan konsistensi struktur dataset sebelum memasuki tahap anotasi dan pemrosesan lebih lanjut. Komposisi lengkap dataset awal dapat dilihat pada Tabel 4.2.

Tabel 4.2 Komposisi Dataset Awal

Sumber Data	**Jumlah**
Rekayasa Dataset *Self-Harm*	524
Media Sosial	268
Meme Umum (Kaggle)	1.400
Total	2192

4.2 Hasil Anotasi Data

Proses anotasi dilakukan menggunakan pendekatan *ensemble pseudo-labeling* dengan dua model *vision-language*, yaitu GPT-4o dan Qwen-VL-Flash, berdasarkan *annotation guideline* dan kerangka *RapGuard* yang telah dirancang pada Bab III. Kedua model memberikan label secara independen terhadap seluruh data, dan label akhir ditentukan berdasarkan konsensus maupun peninjauan manual pada kasus yang tidak konsisten.

4.2.1 Tingkat Kesepakatan Antar Model

Dari seluruh 1.768 data, sebanyak [n] data ([n]%) mendapatkan label yang sama dari kedua model (GPT-4o dan Qwen-VL-Flash), sehingga label tersebut diterima langsung sebagai label akhir. Sementara itu, sebanyak [n] data ([n]%) menunjukkan perbedaan label antar model dan harus ditinjau secara manual oleh peneliti berdasarkan *annotation guideline*.

4.2.2 Distribusi Label Akhir

Tabel 4.3 Distribusi Label Akhir Dataset

Kategori	***Self-Harm***	***Non-Self-Harm***	**Total**
Meme Terkumpul	[n]	[n]	1.768

4.3 Hasil *Pre-processing* Data

Sebelum data digunakan untuk melatih model, seluruh data melalui tahap *pre-processing* yang mencakup pemrosesan modalitas gambar dan teks.

4.3.1 *Pre-processing* Modalitas Gambar

Seluruh gambar diubah ukurannya menjadi 224×224 piksel menggunakan operasi *resize* sesuai dengan kebutuhan masukan *image encoder* CLIP ViT-B/32. Normalisasi piksel kemudian dilakukan menggunakan nilai *mean* dan *standard deviation* yang sesuai dengan konfigurasi pra-latih CLIP.

Untuk data *training*, diterapkan augmentasi data guna meningkatkan keragaman sampel dan mencegah *overfitting*. Teknik augmentasi gambar yang digunakan

meliputi:

1. ***Random Horizontal Flip***: Membalik gambar secara horizontal dengan probabilitas 0.5 untuk meningkatkan invarians terhadap orientasi.
2. ***Random Rotation***: Merotasi gambar secara acak hingga ±15 derajat untuk menangani variasi orientasi meme.
3. ***Color Jitter***: Memvariasikan properti warna gambar dengan parameter *brightness*=0.2, *contrast*=0.2, *saturation*=0.2, dan *hue*=0.1 untuk meningkatkan robustness terhadap variasi pencahayaan dan warna.
4. ***Random Resized Crop***: Melakukan *crop* dan *resize* acak dengan skala antara 0.8–1.0 dari ukuran asli ke resolusi 224×224 piksel untuk meningkatkan invarians terhadap skala dan posisi objek.

Sementara itu, untuk data *testing*, hanya diterapkan operasi *resize* ke 224×224 piksel tanpa augmentasi agar evaluasi dilakukan pada kondisi standar.

4.3.2 *Pre-processing* Modalitas Teks

Teks yang diekstraksi dari meme diproses melalui beberapa tahap sebagai berikut:

1. **Tokenisasi**: Teks diproses menggunakan tokenizer dari model *Suicidal-ELECTRA* yang telah di-*pre-train* pada data terkait *self-harm*.
2. **Pemotongan dan *Padding***: Panjang sekuens maksimum yang digunakan adalah 128 token. Sekuens yang lebih panjang dipotong (*truncation*), sedangkan sekuens yang lebih pendek diisi dengan *padding token* untuk memastikan panjang input yang seragam.
3. ***Attention Mask***: Dibuat *attention mask* untuk membedakan token asli dari *padding token* dalam proses encoding.

Untuk data *training*, diterapkan pula teknik augmentasi teks sederhana dengan probabilitas 30% pada setiap sampel, meliputi:

1. ***Random Deletion***: Menghapus secara acak sekitar 10% kata dari teks untuk meningkatkan robustness terhadap kata yang hilang atau tidak terbaca sempurna.
2. ***Random Swap***: Menukar posisi dua kata secara acak untuk mengurangi

ketergantungan model pada urutan kata yang terlalu rigid.

Augmentasi teks ini diterapkan sebelum proses tokenisasi dan hanya pada data *training*, sementara data *testing* diproses tanpa augmentasi.

4.3.3 Pembagian Dataset

Dataset final dibagi menjadi data *training* dan data *testing* menggunakan metode *stratified random split* dengan rasio 80:20.

Tabel 4.4 Pembagian Dataset

Split	***Self-Harm***	***Non-Self-Harm***	**Total**
Training	[n]	[n]	[n]
Testing	[n]	[n]	[n]

4.4 Hasil Pengembangan Model Multimodal

Model multimodal yang dikembangkan terdiri dari dua komponen *encoder* utama dan sebuah modul *fusion* yang menggabungkan representasi dari kedua modalitas.

4.4.1 Konfigurasi Model

Model mengintegrasikan CLIP ViT-B/32 sebagai *image encoder* dan Suicidal-ELECTRA sebagai *text encoder*, dengan keluaran masing-masing diproyeksikan ke ruang dimensi yang seragam sebelum dilakukan *fusion*.

4.4.2 Konfigurasi *Hyperparameter*

Tabel 4.5 Konfigurasi *Hyperparameter* Pelatihan

Parameter	**Nilai**
Learning Rate	[nilai]
Batch Size	[nilai]
Epochs	[nilai]
Optimizer	AdamW
Loss Function	CrossEntropyLoss
Scheduler	Linear Warmup

4.5 Hasil Eksperimen

Eksperimen pada bagian ini dibagi menjadi dua modalitas utama, yaitu modalitas gambar dan modalitas teks, untuk mengidentifikasi konfigurasi terbaik dalam klasifikasi meme *self-harm*.

4.5.1 Eksperimen Modalitas Gambar

Subbab ini membahas hasil eksperimen pada modalitas gambar menggunakan model *CNN/CLIP Image Encoder*. Evaluasi dilakukan untuk mengetahui pengaruh kombinasi hyperparameter terhadap performa model dalam mengklasifikasikan meme *self-harm*.

4.5.1.1 Hasil Pelatihan Modalitas Gambar

Tabel 4.8 menunjukkan hasil eksperimen terbaik pada modalitas gambar berdasarkan nilai *F1-Score*.

Tabel 4.6 Hasil Terbaik Model Modalitas Gambar

No	Batch	Epoch	LR	Patience	Acc	Prec	Recall	F1	Best Epoch
1	16	24	1e-4	5	-	-	-	-	-
2	32	24	1e-5	5	-	-	-	-	-
3	16	12	1e-5	3	-	-	-	-	-
4	8	24	1e-4	5	-	-	-	-	-
5	16	24	1e-6	5	-	-	-	-	-

Berdasarkan hasil pada Tabel 4.8, kombinasi hyperparameter terbaik diperoleh pada konfigurasi [isi disini]. Hal ini menunjukkan bahwa pemilihan nilai *learning rate* dan *batch size* memiliki pengaruh signifikan terhadap performa model.

4.5.1.2 Analisis Hyperparameter

Analisis dilakukan untuk mengetahui pengaruh *learning rate* terhadap performa model. Parameter lain dibuat konstan untuk memastikan pengaruh yang diamati berasal dari satu variabel utama.

Tabel 4.7 Pengaruh Learning Rate pada Modalitas Gambar

Learning Rate	Accuracy	Precision	Recall	F1-Score	Best Epoch
1e-3	-	-	-	-	-
1e-4	-	-	-	-	-
1e-5	-	-	-	-	-
1e-6	-	-	-	-	-

Dari hasil tersebut, dapat diamati bahwa nilai *learning rate* yang terlalu besar menyebabkan model sulit konvergen, sedangkan nilai yang terlalu kecil memperlambat proses pelatihan. Nilai optimal diperoleh pada [isi].

4.5.1.3 Analisis Proses Pelatihan

Analisis proses pelatihan dilakukan dengan melihat nilai *best epoch* serta kestabilan proses training.

Berdasarkan hasil eksperimen, sebagian besar model mencapai performa terbaik sebelum mencapai jumlah epoch maksimum. Hal ini menunjukkan bahwa mekanisme *early stopping* dengan parameter *patience* yang digunakan telah berjalan dengan baik dalam mencegah terjadinya *overfitting*.

Selain itu, perbedaan nilai *best epoch* pada setiap eksperimen menunjukkan bahwa kombinasi hyperparameter berpengaruh terhadap kecepatan konvergensi model.

4.5.2 Eksperimen Modalitas Teks

Subbab ini membahas hasil eksperimen pada modalitas teks menggunakan model *BERT/ELECTRA*.

4.5.2.1 Hasil Terbaik Model Teks

Tabel 4.8 Hasil Terbaik Model Modalitas Gambar

No	Batch	Epoch	LR	Patience	Acc	Prec	Recall	F1	Best Epoch
1	16	24	1e-4	5	-	-	-	-	-
2	32	24	1e-5	5	-	-	-	-	-
3	16	12	1e-5	3	-	-	-	-	-
4	8	24	1e-4	5	-	-	-	-	-
5	16	24	1e-6	5	-	-	-	-	-

Berdasarkan hasil tersebut, model teks menunjukkan performa terbaik pada konfigurasi [isi], yang mengindikasikan bahwa representasi tekstual memiliki kontribusi penting dalam klasifikasi.

4.5.2.2 Analisis Hyperparameter

Tabel 4.9 Pengaruh Learning Rate pada Modalitas Teks

Learning Rate	Accuracy	Precision	Recall	F1-Score	Best Epoch
1e-3	-	-	-	-	-
1e-4	-	-	-	-	-
1e-5	-	-	-	-	-
1e-6	-	-	-	-	-

Hasil menunjukkan bahwa *learning rate* memiliki pengaruh signifikan terhadap performa model teks, di mana nilai optimal diperoleh pada [isi].

4.5.2.3 Analisis Proses Pelatihan

Berdasarkan hasil eksperimen, model teks menunjukkan kecenderungan konvergensi yang lebih stabil dibandingkan model gambar.

Nilai *best epoch* menunjukkan bahwa model mampu mencapai performa optimal sebelum mencapai epoch maksimum, sehingga penggunaan *early stopping* efektif dalam menghindari overfitting.

“‘latex

4.5.3 Eksperimen Multimodal

Subbab ini membahas eksperimen pada model multimodal yang menggabungkan fitur teks dan gambar. Eksperimen dilakukan untuk mengevaluasi pengaruh dimensi fitur, strategi penanganan *class imbalance*, serta metode *fusion* terhadap performa model.

4.5.3.1 Variasi Dimensi Fitur Teks dan Gambar

Eksperimen ini bertujuan untuk menentukan kombinasi dimensi fitur teks dan gambar terbaik sebelum proses *fusion*. Dimensi fitur teks diperoleh melalui *MLP* sebelum proses *concatenation*, sedangkan fitur gambar disesuaikan untuk menjaga

keseimbangan representasi.

Tabel 4.10 Hasil Eksperimen Variasi Dimensi Fitur

No	Dim Teks	Dim Gambar	Accuracy	Precision	Recall	F1-Score
1	768	512	-	-	-	-
2	768	256	-	-	-	-
3	512	512	-	-	-	-
4	512	256	-	-	-	-
5	256	512	-	-	-	-
6	256	256	-	-	-	-

4.5.3.2 Eksperimen Strategi Penanganan Class Imbalance

Eksperimen ini bertujuan untuk mengevaluasi pengaruh strategi *loss weighting* dalam menangani ketidakseimbangan kelas pada dataset.

Tabel 4.11 Skenario Strategi Loss

No	Strategi	Tujuan
1	Class Weight	Memberikan bobot lebih pada kelas minoritas
2	Focal Loss	Fokus pada sampel sulit
3	Class Weight + Focal Loss	Kombinasi kedua metode

Tabel 4.12 Hasil Eksperimen Strategi Loss

No	Strategi	Accuracy	Precision	Recall	F1-Score
1	Class Weight	-	-	-	-
2	Focal Loss	-	-	-	-
3	Kombinasi	-	-	-	-

4.5.3.3 Eksperimen Metode Fusion

Eksperimen ini bertujuan untuk membandingkan berbagai metode penggabungan fitur (*fusion*) pada model multimodal.

Tabel 4.13 Skenario Metode Fusion

No	Metode Fusion	Deskripsi
1	Concatenation	Penggabungan langsung fitur
2	Addition	Penjumlahan fitur
3	Multiplication	Perkalian elemen fitur
4	Gated Fusion	Penggabungan dengan mekanisme gerbang
5	Attention Fusion	Menggunakan mekanisme perhatian
6	Bilinear Fusion	Interaksi fitur tingkat tinggi

Tabel 4.14 Hasil Eksperimen Metode Fusion

No	Metode Fusion	Accuracy	Precision	Recall	F1-Score
1	Concatenation	-	-	-	-
2	Addition	-	-	-	-
3	Multiplication	-	-	-	-
4	Gated Fusion	-	-	-	-
5	Attention Fusion	-	-	-	-
6	Bilinear Fusion	-	-	-	-

Berdasarkan hasil eksperimen, metode fusion terbaik diperoleh pada [isi], yang menunjukkan bahwa strategi penggabungan fitur memiliki pengaruh signifikan terhadap performa model multimodal. “‘

4.6 Analisis Kesalahan (*Error Analysis*)

Analisis kesalahan dilakukan terhadap model terbaik untuk memahami pola kesalahan klasifikasi secara lebih mendalam.

4.6.1 Kasus *False Positive*

False positive merupakan kondisi di mana model memprediksi suatu meme sebagai *self-harm* padahal label sesungguhnya adalah *non-self-harm*. Beberapa pola kasus yang ditemukan antara lain:

1. Meme yang menggunakan *dark humor* atau humor bertemakan kematian secara tidak serius.
2. Meme dengan gambar objek yang secara visual berasosiasi dengan bahaya namun tidak berkaitan dengan *self-harm*.
3. Meme yang menggunakan referensi budaya populer yang berkaitan dengan tema melankolis.

4.6.2 Kasus *False Negative*

False negative merupakan kondisi di mana model gagal mengidentifikasi meme *self-harm*. Pola kasus yang ditemukan antara lain:

1. Meme dengan indikator *self-harm* yang sangat implisit menggunakan kiasan atau metafora.

2. Meme tanpa teks atau dengan teks yang sangat minimal.
3. Meme yang menggunakan referensi komunitas daring yang bersifat *in-group*.

4.7 Pembahasan

Subbab ini menyajikan pembahasan menyeluruh terhadap hasil eksperimen yang telah dilakukan.

4.7.1 Keterkaitan dengan Rumusan Masalah

Penelitian ini berhasil menjawab seluruh rumusan masalah yang telah ditetapkan melalui pengembangan model multimodal, penyusunan dataset yang komprehensif, dan evaluasi performa yang menyeluruh.

4.7.2 Perbandingan dengan Penelitian Terdahulu

Kinerja model yang dikembangkan dalam penelitian ini menunjukkan peningkatan signifikan dibandingkan dengan pendekatan unimodal dan model-model sebelumnya yang tidak spesifik pada domain *self-harm*.

4.7.3 Implikasi dan Limitasi Penelitian

Temuan dalam penelitian ini memiliki implikasi praktis dalam pengembangan sistem moderasi konten otomatis berbasis kecerdasan buatan. Namun penelitian ini memiliki beberapa limitasi, termasuk penggunaan *pseudo-labeling* tanpa validasi manusia penuh, fokus pada konten berbahasa Inggris, dan tantangan dalam mendeteksi meme dengan metafora budaya spesifik.

BAB V
KESIMPULAN DAN SARAN

5.1 Kesimpulan

Berdasarkan penelitian yang telah dilakukan, maka kesimpulan yang diperoleh adalah sebagai berikut:

1. Berdasarkan pengujian
2. mengimplementasikan

5.2 Saran

Adapun saran yang dapat diberikan untuk penelitian lebih lanjut berdasarkan penelitian ini adalah sebagai berikut:

1. Pengembangan
2. Tampilan

DAFTAR PUSTAKA

[1] Abdul Wahab Syakhrani and Engelbertus Kukuh Widijatmoko. "Perkembangan Komunikasi Digital: Dampak Media Sosial pada Interaksi Sosial di Era Modern". *Jurnal Komunikasi* 2.12 (Dec. 2024).

[2] DataReportal. *Digital 2024: Global Overview Report*. https://datareportal.com/reports/digital-2024-global-overview-report. [Online; accessed 2024]. 2024.

[3] DataReportal. *5 Billion Social Media Users – Global Digital Insights*. https://datareportal.com/reports/digital-2024-deep-dive-5-billion-social-media-users. [Online; accessed 2024]. 2024.

[4] Limor Shifman. "Memes in a Digital World: Reconciling with a Conceptual Troublemaker". *Journal of Computer-Mediated Communication* 18 (Apr. 2013), n/a–n/a.

[5] Shivam Sharma et al. *Detecting and Understanding Harmful Memes: A Survey*. 2022. arXiv: 2205.04274 [cs.CL].

[6] National Institute for Health and Care Excellence (NICE). *Self-harm: assessment, management and preventing recurrence*. Guideline NG225. National Institute for Health and Care Excellence. Sept. 2022.

[7] World Health Organization. *Title Unknown — IRIS Document 82c0b481-3d64-48bc-b403-a3e43300f6ef*. Accessed via WHO IRIS digital repository. 2026.

[8] Yukari Seko et al. "On the Creative Edge: Exploring Motivations for Creating Non-Suicidal Self-Injury Content Online". *Qualitative Health Research* 25.10 (2015), pp. 1334–1346.

[9] Y. Zhang, X. Liu, H. Wang, et al. "The impact of social media on self-harm behaviors: A review and future directions". *Smart Health* (2025). 2949-7329.

[10] Samaritans. *Samaritans report reveals dangers of social media's self-harm content*. https://www.samaritans.org/news/samaritans-report-reveals-dangers-of-social-medias-self-harm-content/. Press Release. [Online; accessed November 2025]. Nov. 2022.

[11] World Health Organization. *Adolescent mental health*. https://www.who.int/news-room/fact-sheets/detail/adolescent-mental-health. Diakses: 29 November 2025. 2025.

[12] Tadas Baltrusaitis, Chaitanya Ahuja, and Louis-Philippe Morency. "Multimodal Machine Learning: A Survey and Taxonomy". *arXiv* abs/1705.09406 (2018).

[13] Douwe Kiela et al. *The Hateful Memes Challenge: Detecting Hate Speech in Multimodal Memes*. 2020. arXiv: 2005.04790 [cs.AI].

[14] Pranav Shah et al. "MemeCLIP: Leveraging CLIP Representations for Multimodal Meme Classification". *arXiv preprint arXiv:2403.11245* (2024).

[15] Dong-Hyun Lee. "Pseudo-Label : The Simple and Efficient Semi-Supervised Learning Method for Deep Neural Networks". *ICML 2013 Workshop : Challenges in Representation Learning (WREPL)* (July 2013).

[16] Y. Zhang et al. "The impact of social media on self-harm behaviors: A review and future directions". *JAACAP Open* 1.1 (2025), p. 100023. 2949-7329.

[17] Alec Radford et al. *Learning Transferable Visual Models from Natural Language Supervision*. 2021. arXiv: 2103.00020 [cs.CV].

[18] Kevin Clark et al. "ELECTRA: Pre-training Text Encoders as Discriminators Rather Than Generators". *arXiv preprint arXiv:2003.10555* (2020).

[19] Said Yacine Boulahia et al. "Early, intermediate and late fusion strategies for robust deep learning-based multimodal action recognition". *Machine Vision and Applications* 32.6 (Sept. 2021), p. 121.

[20] Dong-Hyun Lee. "Pseudo-Label: The Simple and Efficient Semi-Supervised Learning Method for Deep Neural Networks". *ICML Workshop*

on Challenges in Representation Learning (WREPL). Atlanta, Georgia, USA, 2013.

[21] Shubham Pramanick et al. "MOMENTA: A Multimodal Framework for Detecting Harmful Memes and Their Targets". *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. 2021, pp. 10374–10388.

[22] Anup Kumar and Karthik Nandakumar. "Hate-CLIPper: Multimodal Hateful Meme Classification based on Cross-modal Interaction of CLIP Features". *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops*. 2022.

[23] Zheng Lian et al. "GPT-4V with Emotion: A Zero-shot Benchmark for Generalized Emotion Recognition". *arXiv preprint arXiv:2312.04293* (2023).

[24] World Health Organization. *Preventing suicide: A global imperative*. Geneva, Switzerland: World Health Organization, 2014. ISBN: 978-92-4-156477-9.

[25] American Psychiatric Association. *Diagnostic and Statistical Manual of Mental Disorders (5th ed., text rev.)* American Psychiatric Association, 2022.

[26] Florian Arendt, Sebastian Scherr, and Daniel Romer. "Effects of exposure to self-harm on social media: Evidence from a two-wave panel study among young adults". *New Media & Society* 21.11-12 (2019).

[27] Jiquan Ngiam et al. "Multimodal Deep Learning". *Proceedings of the 28th International Conference on Machine Learning (ICML 2011)*. 2011, pp. 689–696.

[28] IBM. *What is AI multimodal?* https://www.ibm.com/think/topics/multimodal-ai. Accessed 9 December 2025. July 2024.

[29] Tianzhe Jiao et al. "A Comprehensive Survey on Deep Learning Multi-Modal Fusion: Methods, Technologies and Applications". *Computers, Materials & Continua* 80.1 (2024), pp. 1–35.

[30] Tadas Baltrusaitis, Chaitanya Ahuja, and Louis-Philippe Morency. “Multimodal Machine Learning: A Survey and Taxonomy”. *IEEE Transactions on Pattern Analysis and Machine Intelligence* 41.2 (2019), pp. 423–443.

[31] *Computer Vision – an overview*. Diakses pada 9 Desember 2025. ScienceDirect Topics. n.d.

[32] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. “Deep learning”. *Nature* 521.7553 (2015), pp. 436–444.

[33] Alexey Dosovitskiy et al. “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale”. *arXiv preprint arXiv:2010.11929* (2020).

[34] Tom Young et al. “Recent Trends in Deep Learning Based Natural Language Processing”. *arXiv preprint arXiv:1708.02709* (2017).

[35] Jacob Devlin et al. “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. *arXiv preprint arXiv:1810.04805* (2018).

[36] Jürgen Schmidhuber. “Deep learning in neural networks: An overview”. *Neural Networks* 61 (2015), pp. 85–117.

[37] Ashish Vaswani et al. “Attention Is All You Need”. *arXiv preprint arXiv:1706.03762* (2017).

[38] Xuran Pan et al. “Contrastive Language-Image Pre-Training with Knowledge Graphs”. *arXiv preprint arXiv:2210.08901* (2022). Preprint.

[39] Sentinet. *ELECTRA model for suicidality detection*. 2023.

[40] Mingle Xu et al. “A Comprehensive Survey of Image Augmentation Techniques for Deep Learning”. *Pattern Recognition* 137 (2023), p. 109347.

[41] Connor Shorten and Taghi M. Khoshgoftaar. “A survey on Image Data Augmentation for Deep Learning”. *Journal of Big Data* 6.1 (2019), p. 60.

[42] Tom Fawcett. “Introduction to ROC Analysis”. *Pattern Recognition Letters* 27.8 (June 2006), pp. 861–874.

[43] Marina Sokolova and Guy Lapalme. “A Systematic Analysis of Performance Measures for Classification Tasks”. *Information Processing & Management* 45.4 (July 2009), pp. 427–437.

[44] David M. W. Powers. *Evaluation: from precision, recall and F-measure to ROC, informedness, markedness and correlation*. 2020. arXiv: 2010.16061 [cs.LG].

[45] Raquel Moraleda-Esteban and Esther Martínez-Pastor. "Self-harm, adolescents and mental health on social media and in the family environment: from the perspective of health professionals". *Quaderns del CAC* 51 (Feb. 2025), pp. 17–28. 2014-2242.

[46] Md Mafiul Hasan Matin Mafi and Md. Sabbir Alam. *Suicidal Ideation Detection Reddit Dataset*. Version 2. 2023.

[47] Zain Ali. *Weapon and Knife Detection (137K Images)*. https://www.kaggle.com/datasets/zinkzsa/weapon-and-knife-detection-137k-images. Accessed: Dec. 7, 2025. 2025.

[48] Karima Susi et al. "Viewing self-harm images on the internet and social media platforms: systematic review of the impact and associated psychological mechanisms". *Journal of Child Psychology and Psychiatry* 64.8 (2023), pp. 1115–1139.

[49] Hammad Javaid. *6992 Labeled Meme Images Dataset*. https://www.kaggle.com/datasets/hammadjavaid/6992-labeled-meme-images-dataset. Accessed: Dec. 7, 2025. 2023.

[50] Alexander Ratner et al. "Data Programming: Creating Large Training Sets, Quickly". *Advances in Neural Information Processing Systems (NeurIPS)*. 2019.

[51] Yilei Jiang, Yingshui Tan, and Xiangyu Yue. "RapGuard: Safeguarding Multimodal Large Language Models via Rationale-aware Defensive Prompting". *arXiv preprint arXiv:2412.18826* (2024).

[52] Yasin Dus and Georgiy Nefedov. "An Automated Tool to Detect Suicidal Susceptibility from Social Media Posts". *Suicidal Text Detection Report* (2022). Accessed: 2025-12-10.

LAMPIRAN